

LLM101n-BR

Gabaritos comentados

Construindo um Modelo de Linguagem do Zero

Curso bilingue inspirado no LLM101n

Gerado em 10/08/2026

Gabarito — Capítulo 01

Respostas discursivas. Os **números** vêm de `gabarito.py`, que roda os experimentos; rode-o e compare com os seus resultados.

E1 — Leitura de código

1. Por que `vocab_size` é 27, e não 26? São as 26 letras `a-z` mais o token especial de fronteira `.`, que marca início e fim de nome. Sem ele o modelo não saberia com que letra começar nem quando parar.

2. O que aconteceria trocando `(N + 1)` por `N` no cálculo da *loss*? Bigramas nunca vistos teriam contagem 0, logo probabilidade 0, e `log(0) = -infinito` — a *loss* viraria infinita.

Um detalhe que o `gabarito.py` mostra e que vale entender: com este dataset, avaliando **nos mesmos dados do treino**, a *loss* com `+0` sai finita (2,1473). Isso porque todo bigrama avaliado foi, por definição, visto no treino. O infinito aparece assim que você avalia um nome **nov**o que contenha um par inédito. É por isso que se suaviza mesmo quando "parece funcionar".

3. Para que serve o `manual_seed`? Fixa o gerador de números aleatórios, tornando a execução **reprodutível** — você e eu vemos os mesmos nomes gerados. Útil para estudar e depurar; em produção você deixaria aleatório.

E2 — Mexa nos dados

Medido (`gabarito.py`):

Dataset	Loss
155 nomes originais	2,3832
+ 5 nomes estranhos (<code>zwqk</code> , <code>xyzabc</code> ...)	2,3982 (+0,0150)
+ 5 nomes típicos (<code>ana</code> , <code>maria</code> ...)	2,3750 (-0,0081)

A resposta correta é "depende", e é isso que o exercício quer ensinar. Não existe "mais dados = *loss* menor". O que existe é: dados que **seguem o padrão** que o modelo já capturou reduzem a *loss*; dados com padrões **raros** a aumentam, porque o modelo precisa gastar probabilidade em bigramas incomuns.

Se você acrescentou nomes de amigos (portugueses, típicos), provavelmente viu a *loss* cair um pouco. Se acrescentou nomes inventados esquisitos, viu subir.

E3 — O efeito da suavização

Suavização	Loss
+0	2,1473
+1	2,3832
+10	2,8674
+100	3,2114

1. A loss **cresce** monotonicamente com a suavização. Suavizar afasta o modelo dos dados observados.
2. Os nomes gerados ficam mais **genéricos e aleatórios** conforme a suavização aumenta — a distribuição tende ao uniforme, e o modelo "esquece" o que aprendeu. Com +0 eles grudam mais nos padrões do dataset.
3. Ver E1.2 acima: +0 produz probabilidade zero para pares não vistos, e o $\log(0)$ quebra a conta assim que você sai dos dados de treino.

E4 — Temperatura no sampling

Medido, com a mesma semente:

T	Nomes gerados
0,3	celia, lo, la, ria, ca
1,0	cexzma, ogosuraro, zktahwelo, imjtta
3,0	cexzm, loglkurkicczktyh, mvlzimjttainrlkf

1. T **baixo** -> nomes mais "óbvios", curtos e repetitivos: a temperatura concentra a massa de probabilidade nas opções mais prováveis. T **alto** -> mais aleatórios e impronunciáveis: ela achata a distribuição.
2. É exatamente o parâmetro **temperature** das APIs de LLM. Note a forma usada: $p^{**}(1/T)$. Com $T < 1$ o expoente é maior que 1, o que **acentua** as diferenças entre as probabilidades; com $T > 1$ ele as **achata**. Nos modelos modernos a mesma operação é aplicada aos *logits* antes do softmax (dividir os logits por T), o que é matematicamente equivalente.

E5 — Igualando contagem e rede neural

Configuração	Loss
--------------	------

Contagem +1	2,3832
Contagem +0,01	2,1518
Rede, reg=0.01 , 200 passos	2,1774
Rede, reg=0.0 , 1000 passos	2,1600

1 e 2. Com a suavização **igualada** dos dois lados, os valores convergem para a mesma faixa (~2,15-2,18).

3. É a confirmação da tese do capítulo: contar e otimizar chegam ao **mesmo modelo**. A diferença que se via na apostila (2,38 contra 2,21) vinha só do fato de que o **+1** é uma suavização **muito mais forte** que o **reg=0.01**. São o mesmo botão, em escalas diferentes.

E6 — NLL de um nome específico

Solução em `e6_nll_de_nome.py`. Resultados:

```
ana -> NLL = 1.7871
maria -> NLL = 1.7626
vinicius -> NLL = 2.4613
xwq -> NLL = 3.6696
kffkz -> NLL = 3.4179
```

- 1.** `ana` tem NLL bem menor que `xwq` — o modelo considera `ana` muito mais provável.
- 2.** Nomes com bigramas comuns em português (`ma`, `ri`, `an`) pontuam bem. Nomes com sequências raras (`xw`, `kz`) pontuam mal. `vinicius` fica no meio: tem `vi` e `ni` comuns, mas `ci` seguido de `us` é menos frequente no dataset.

E7 — Rumo ao trigrama

Modelo	Suavização	Loss
Bigrama	+0,01	2,1518
Trigrama	+1,0	2,3449
Trigrama	+0,01	1,1523

- 1.** A tabela passa de $27 \times 27 = 729$ para $27 \times 27 \times 27 = \textbf{**19.683**}$ células.
- 2.** Com suavização comparável (**+0,01**), a loss **melhora muito**: 2,15 -> 1,15. Mais contexto ajuda de verdade.

Atenção ao efeito da suavização aqui: com $+1$, o trigrama fica *pior* que o bigrama (2,34 contra 2,15). Isso não é o trigrama sendo ruim — é que somar 1 a **19.683** células injeta muito mais "massa uniforme" do que somar 1 a 729. Quanto maior a tabela, mais destrutiva é a mesma suavização. Comparar modelos com suavização fixa é comparar coisas diferentes.

3. O problema novo é a **esparsidade**: a maioria das células nunca é preenchida. A suavização evita o $\log(0)$, mas **não inventa informação** — para combinações nunca vistas o modelo apenas chuta uniformemente. E isso piora exponencialmente: com k caracteres de contexto são $27^{(k+1)}$ células.

É exatamente essa parede que motiva o **Capítulo 3**: em vez de contar células, o MLP aprende uma representação **densa e compartilhada**, onde contextos parecidos se apoiam mutuamente.

Gabarito — Capítulo 02

Respostas discursivas. Os **números** vêm de `gabarito.py`.

E1 — Leitura de código

1. Para `f = a * b` com `a = 3`, `b = 4`: `df/da = b = 4` e `df/db = a = 3`. A derivada em relação a um fator é o **outro** fator.
2. Para `d = a*b + c`: `dd/dc = 1`. A soma não altera o gradiente porque a derivada de uma soma em relação a cada parcela é 1 — ela apenas **distribui** o gradiente que chega, sem escalá-lo. É por isso que, no código, o `_backward` da soma é `self.grad += 1.0 * out.grad`.
3. Por que **tanh saturada tem gradiente quase zero**: a derivada é `1 - tanh(x)2`. Para `x` grande, `tanh(x) -> ±1`, logo `tanh(x)2 -> 1` e a derivada `-> 0`. Nas regiões extremas a curva é praticamente horizontal — mexer na entrada quase não muda a saída, e o gradiente morre. É o mesmo efeito que reaparece no softmax do Capítulo 4 (daí o fator `1/√d`) e na inicialização do Capítulo 7.

E2 — Conferindo com diferença finita

Variável	Autograd	Diferença finita	Erro relativo
<code>a</code>	-0,00402285	-0,00402285	5,97e-10
<code>b</code>	+0,00268190	+0,00268190	5,97e-10
<code>c</code>	+0,00134095	+0,00134095	5,97e-10

Batem. Dois detalhes que valem a pena:

- Usamos a **diferença central**, `(f(x+h) - f(x-h)) / 2h`, e não a ingênua `(f(x+h) - f(x)) / h`. A central tem erro `O(h2)` em vez de `O(h)` — bem mais precisa pelo mesmo custo.
- Existe um **h ótimo**: grande demais e a aproximação da derivada é ruim; pequeno demais e o cancelamento em ponto flutuante domina (você subtrai dois números quase iguais). Por volta de `1e-6` costuma ser um bom meio-termo em `float64`.

Esta é a forma clássica de **testar** um autograd, e é o que bibliotecas de verdade usam nos seus testes (`torch.autograd.gradcheck` faz exatamente isso).

E3 — Implementando `log()`

1. A derivada local é `d(ln x)/dx = 1/x`.

2. Seguindo o padrão de sempre — derivada local vezes o gradiente que vem de fora:

```
def log(self):
    out = Value(math.log(self.data), (self,), "log")
    def _backward():
        self.grad += (1.0 / self.data) * out.grad
    out._backward = _backward
    return out
```

3. Verificado: $\log(3.0) = 1,098612$ (bate com `math.log`), e $d(\log)/dx = 0,333333$ contra `0,333333` da diferença finita — erro de $4,66e-11$.

Cuidado que o exercício não pede mas vale saber: `log` só é definido para $x > 0$. Numa implementação séria você trataria $x \leq 0$ explicitamente, em vez de deixar o `math.log` levantar exceção no meio de um treino.

E4 — Por que zerar o gradiente

Medido, 20 passos:

Configuração	passo 0	passo 5	passo 19
com <code>zero_grad</code>	3,0929	0,0006	0,0001
sem <code>zero_grad</code>	3,0929	0,7659	0,6158

1 e 2. Leia os números, não a intuição. Sem o `zero_grad` o treino **não explode neste caso — ele estagna**. A loss cai até ~0,6 e trava, enquanto com `zero_grad` chega a 0,0001.

Por que estagna em vez de divergir? Os gradientes são acumulados com `+=`, então o gradiente do passo N é a soma de todos os anteriores. Isso produz dois efeitos que se combatem: o passo fica **grande demais** (empurra para divergir) mas também **desatualizado** — carrega direções calculadas para pesos que já mudaram. Aqui o modelo entra num vai-e-vem e não converge. Com learning rate maior, ou em outros problemas, o mesmo bug realmente diverge.

3. É exatamente o `W.grad = None` do Capítulo 1, pelo mesmo motivo.

A lição que mais importa: o resultado fica errado de um jeito que **não se parece com um erro**. Não há exceção, não há `NaN` — só um treino pior. Bugs assim são os mais caros de encontrar, e é por isso que se compara sempre contra uma referência.

E5 — Bate com o PyTorch?

Solução em `e5_check_vs_torch.py`. Resultado: `ALL MATCH: True`, com diferença máxima de $8,94e-08$.

2. Trocando `tanh` por `relu`, continuam batendo — o mecanismo é o mesmo, só muda a derivada local registrada por aquela operação.

E6 — Arquitetura e learning rate

Arquitetura	Parâmetros	Loss final	Situação
[4, 4, 1]	41	0,000000	convergiu
[8, 1]	41	0,000000	convergiu
[16, 16, 1]	353	1,38e+147	DIVERGIU

Learning rate	Loss final	Situação
0,5	1,80e+248	DIVERGIU
0,05	0,000000	boa
0,001	0,136863	lenta demais

1. A primeira resposta contraria o senso comum. [4,4,1] e [8,1] convergem — e, por coincidência, têm exatamente os **mesmos 41 parâmetros**. Mas [16,16,1], com 353 parâmetros, **diverge** com a mesma learning rate.

Rede maior não é automaticamente melhor. Com mais parâmetros, a soma dos gradientes fica maior, e uma `lr` que servia para a rede pequena passa a ser grande demais. **A learning rate adequada depende do tamanho do modelo** — que é justamente o que motiva a inicialização escalada e o agendamento do Capítulo 7.

2. A curva em U clássica: `0,5` diverge, `0,05` converge, `0,001` quase não anda no orçamento de 100 passos. O Capítulo 7 mede isso de forma sistemática (exercício E5 de lá).

3. Trocar `tanh` por `relu` neste problema faz pouca diferença: com 4 pontos de dados, qualquer não-linearidade razoável resolve. A diferença entre ativações aparece em redes profundas, e é o assunto da Seção 2 do Capítulo 7.

E7 — Visualizando o grafo

Implementação em `gabarito.py`. Para `(a*b + c).tanh()`:

```
Value(data=0.9993, grad=1.0000) [tanh]
+-- Value(data=4.0000, grad=0.0013) [+]
+-- Value(data=10.0000, grad=0.0013)
+-- Value(data=-6.0000, grad=0.0013) [*]
+-- Value(data=2.0000, grad=-0.0040)
```

```
+- - Value(data=-3.0000, grad=0.0027)
```

Leia de cima para baixo: a raiz é a saída, e cada nível mostra os "pais" que a produziram. A `backward()` percorre exatamente esta estrutura, aplicando a regra da cadeia.

Repare em como o gradiente se comporta:

- O `tanh` na raiz tem `grad = 1.0` (é a semente, $d(\text{saída})/d(\text{saída}) = 1$).
- A **soma** distribui `0,0013` igualmente para `c` e para o produto — sem alterar nada.
- A **multiplicação** escala: `a` recebe $0,0013 \times (-3) = -0,0040$ e `b` recebe $0,0013 \times 2 = 0,0027$.

Cada um multiplicado pelo valor do outro.

E note que todos os gradientes são pequenos ($\sim 1e-3$): a `tanh` está saturada em `x = 4`, o que confirma o que a resposta do E1.3 previu.

Gabarito — Capítulo 03

Respostas discursivas. Os **números** vêm de `gabarito.py`.

Sobre o orçamento: o gabarito treina **4.000 passos** (a apostila usa 20.000) para rodar em poucos minutos. Os valores absolutos ficam piores que os da apostila, mas as **comparações entre configurações** — que é o que os exercícios pedem — continuam válidas. Onde essa diferença muda a conclusão, está dito explicitamente (veja o E4).

E1 — Leitura de código

1. Por que `emb = C[X]` tem formato `(N, 3, 10)`? `X` tem formato `(N, 3)`: `N` exemplos, 3 índices de caractere cada. `C[X]` substitui cada índice pela linha correspondente de `C`, que tem 10 números. Então: `N` exemplos $\times$ 3 posições de contexto $\times$ 10 dimensões de embedding.
2. Por que o `.view(N, -1)` antes da camada linear? A camada linear espera um vetor por exemplo, não uma matriz `3 $\times$ 10`. O `view` reorganiza os mesmos números em `(N, 30)`, colando os três embeddings num vetor só. O `-1` diz ao PyTorch "calcule esta dimensão". Note que `view` não copia dados — apenas reinterpreta o mesmo bloco de memória.
3. O que `F.cross_entropy(logits, Y)` faz? Exatamente o que fizemos à mão no Capítulo 1: **softmax** seguido de **negative log-likelihood**. A diferença é que a versão do PyTorch é numericamente estável (evita `exp()` de números grandes, que estouraria) e mais rápida.

E2 — O efeito do contexto

<code>block_size</code>	Parâmetros	Treino	Validação
1	7.897	2,3498	2,3401
3	11.897	2,0508	2,0452
5	15.897	2,0165	2,0114

1. Mais contexto **ajuda**: a validação cai de 2,34 para 2,01.
2. Com `block_size = 1` o MLP vira um **bigrama neural** — ele só vê o caractere anterior, como no Capítulo 1. E de fato a loss (2,34) cai na faixa do bigrama daquele capítulo (~2,4). É uma boa confirmação de que os dois modelos são a mesma coisa quando o contexto é o mesmo.
3. Sim, os parâmetros crescem: a primeira camada tem `(n_embd  $\times$  block_size)  $\times$  n_hidden` pesos. Cada caractere a mais de contexto acrescenta `n_embd  $\times$  n_hidden = 2.000` pesos.

É exatamente esse custo linear que motiva a **atenção** do Capítulo 4: lá, aumentar o contexto **não** aumenta o número de parâmetros.

E3 — Tamanho da camada oculta

<code>n_hidden</code>	Parâmetros	Treino	Validação
50	3.197	2,1128	2,1023
200	11.897	2,0508	2,0452
500	29.297	2,0287	2,0271

1. Mais neurônios, mais parâmetros, loss menor.

2. **Retorno decrescente, e claro:** de 50 para 200 (parâmetros $\times 3,7$) a validação melhora 0,057. De 200 para 500 (parâmetros $\times 2,5$) melhora só 0,018 — três vezes menos ganho. Cada parâmetro novo contribui menos que o anterior.

E4 — Learning rate

<code>lr</code>	Validação	Situação
0,001	2,4547	lenta demais
0,01	2,2162	
0,1	2,0452	<- o valor da apostila
1,0	2,0019	melhor aqui
10,0	—	divergiu
50,0	—	divergiu

1. Esta resposta provavelmente contraria o que você esperava. A curva é em U, mas o mínimo **não** está no **0,1** que a apostila usa — neste orçamento de 4.000 passos, `lr = 1,0` vai melhor. A divergência só aparece em **10,0**.

Isso **não** significa que a apostila esteja errada. Ela treina 20.000 passos, e com orçamento maior uma learning rate menor tem tempo de refinar e chega mais longe. A conclusão correta:

A melhor learning rate depende do orçamento de passos. Ela não é uma propriedade do modelo. O mesmo fenômeno reaparece no Capítulo 7 (exercício E5), onde $3e-3$ ganha de $1e-3$ justamente porque o experimento treina menos passos que a apostila.

2. Removendo o decaimento com a melhor **lr**: 2,0915 sem contra **2,0019** com — o decaimento vale **0,09** de loss. Passos menores no fim permitem "assentar" no mínimo em vez de ficar pulando em torno dele.

E5 — Overfitting com dataset pequeno

Solução em `e5_overfitting.py`:

```
=== DATASET PEQUENO (155 nomes) ===  
loss treino = 0.8001  
loss validacao = 6.5086
```

1. Um abismo: treino 0,80 contra validação 6,51.
2. O mesmo modelo generaliza com 64 mil nomes e decora com 155 porque o número de **parâmetros** (11.897) é maior que o número de **exemplos de treino** (880). Com essa proporção, memorizar é mais fácil que aprender o padrão — e o modelo faz o que é mais fácil. (É a mesma conta que reaparece no Capítulo 11: 0,28 token por parâmetro.)
3. Os nomes gerados se parecerem demais com nomes reais do dataset é **mau** sinal porque significa que o modelo está **reproduzindo**, não **generalizando**. Um bom modelo gera nomes que *poderiam* estar na lista mas não estão. Qualidade aparente na saída pode esconder memorização — por isso se mede na validação, não no olho.

E6 — Visualizando os embeddings

Com `n_embd = 2` (treino 2,2954 / validação 2,2873 — pior que com 10, como esperado):

Distância média	Valor
vogal <-> vogal	0,732
vogal <-> consoante	1,173
razão	1,60x

1. **As vogais ficam agrupadas.** Elas estão 1,6x mais próximas entre si do que das consoantes. A rede descobriu sozinha que vogais têm papel parecido — **só por prever o próximo caractere**. Ninguém ensinou fonética a ela.

Este é um dos resultados mais bonitos do curso: estrutura linguística emergindo de pura estatística de sequência.

2. Reduzir para `n_embd = 2` piora a loss (menos capacidade por caractere), mas é o único jeito de desenhar os embeddings num plano. É um trade-off comum em interpretabilidade: sacrifica-se desempenho para poder **ver**. (Em modelos de verdade usa-se PCA ou t-SNE para projetar embeddings de centenas de dimensões em 2, sem retreinar.)

E7 — Contando os parâmetros

Componente	C Total
<code>C</code> (embeddings)	27270 × 10
<code>W1</code>	306.000 × 200
<code>b1</code>	20000
<code>W2</code>	206.400 × 27
<code>b2</code>	2727
Total	11.897

1. Fórmula geral:

```
vocab×n_embd + (n_embd×block_size)×n_hidden + n_hidden + n_hidden×vocab + vocab
```

2. Confere exatamente com o `11897` que o código informa.

3. **Quem domina:** `W1` (6.000) e `W2` (5.400) somam **96%** do total. As duas matrizes grandes são o modelo; embeddings e vieses são detalhes.

Consequências:

- Dobrar `n_embd` quase dobra o total (ele aparece em `C` e em `W1`).
- Dobrar `n_hidden` também (aparece em `W1` e em `W2`).
- Dobrar `block_size` só afeta `W1` — cresce menos que os outros dois.

Gabarito — Capítulo 04

Respostas discursivas. Os **números** vêm de `gabarito.py`.

Orçamento: 4.000 passos por configuração (a apostila usa 20.000). Valores absolutos ficam piores; as comparações continuam válidas.

E1 — Leitura de código

1. O que a `tril` impede, e o que aconteceria sem ela no treino? Ela impede que uma posição veja o **futuro**. Sem ela, ao prever o token seguinte a posição poderia consultar justamente a resposta — a loss de treino despencaria e o modelo não aprenderia nada útil, porque na hora de gerar texto o futuro não existe. É *data leakage*.

(O exercício E2 mostra que isso tem uma sutileza importante — veja abaixo.)

2. Por que dividir por $\sqrt{\text{head_size}}$? O produto escalar $q \cdot k$ é a soma de `head_size` produtos, então a sua magnitude cresce com a dimensão. Pontuações grandes fazem o softmax **saturar**: a distribuição vira quase um one-hot e o gradiente morre. Dividir por $\sqrt{\text{head_size}}$ mantém a variância em torno de 1 independentemente do tamanho da cabeça.

3. Query, key e value:

- **query:** "o que eu estou procurando?"
- **key:** "o que eu tenho a oferecer?" (o endereço pelo qual sou encontrado)
- **value:** "o que eu de fato entrego, se você me escolher" (o conteúdo)

Separar *key* de *value* dá liberdade ao modelo: como sou encontrado e o que eu entrego são coisas diferentes.

E2 — Sem a máscara causal

Este exercício tem uma armadilha que vale mais que a pergunta.

Configuração	Treino	Validação
1 camada, máscara ON	2,1589	2,1517
1 camada, máscara OFF	2,1589	2,1517
2 camadas, máscara ON	2,2238	2,2122
2 camadas, máscara OFF	2,1614	2,1513

Com uma camada, remover a máscara não muda absolutamente nada. Os números são idênticos até a quarta casa. Não é erro de medição.

O motivo é estrutural: este modelo usa **apenas a última posição** para prever, e a última linha da matriz triangular **já é toda de uns**. Para a posição que importa, a máscara nunca fez diferença — ela só afetava posições intermediárias, cujas saídas são **descartadas**.

Com duas camadas a história muda. A saída das posições intermediárias da camada 1 alimenta a camada 2, e a última posição da camada 2 as lê. Aí o futuro realmente vaza, e a loss sem máscara fica artificialmente melhor (2,1513 contra 2,2122).

E onde a máscara é absolutamente essencial: quando o modelo prevê em **todas** as posições (Capítulo 11). Ali a posição **t** veria literalmente o token **t+1** que deve prever — vazamento direto e devastador.

A lição: uma proteção pode estar **correta** e ainda assim ser **inócua** no desenho atual. Removê-la e não ver diferença **não prova que é inútil** — prova que o seu teste não exercita o caminho que ela protege. É exatamente assim que proteções de segurança são removidas "porque não faziam nada".

E3 — Sem o embedding posicional

Configuração	T Validação
com posicional	2,151317
sem posicional	2,211959
diferença	+0,0442

1 e 2. A loss piora. A atenção é **invariante a permutações**: ela calcula afinidades entre pares de posições, mas nada no mecanismo diz **qual veio antes**. Sem o embedding posicional, **ana** e **naa** viram o mesmo conjunto de tokens, e o modelo perde a capacidade de usar a **ordem** — que em linguagem é quase tudo.

A penalidade de 0,044 pode parecer modesta, mas note: para *nomes*, boa parte do sinal está em *quais* letras aparecem (estatística de caracteres), não só na ordem. Em prosa, o mesmo experimento seria muito mais destrutivo.

E4 — Sem a escala $1/\sqrt{\text{head_size}}$

Configuração	Treino	Validação	Peso máximo médio de atenção
com escala	2,1589	2,1517	0,406

sem escala	2,3508	2,3428	0,985
------------	--------	--------	--------------

1 e 2. Sem a escala a loss piora bastante (+0,19), e a causa aparece na terceira coluna: o peso máximo por linha sobe de 0,41 para **0,985**. A distribuição de atenção virou praticamente um **one-hot** — o modelo escolhe uma posição e ignora todas as outras.

3. Softmax saturado tem gradiente quase nulo. É exatamente o mesmo efeito da **tanh** saturada do Capítulo 2: o modelo trava numa escolha e perde a capacidade de ajustá-la. A escala não é um detalhe de normalização — é o que mantém o mecanismo **treinável**.

E5 — Tamanho do contexto

block_size	Parâmetros	Treino	Validação
3	11.103	2,2194	2,2110
8	11.363	2,1589	2,1517
16	11.779	2,2122	2,1988

1. A resposta não é "mais contexto é sempre melhor". De 3 para 8 melhora; de 8 para 16 **piora**. Não é retorno decrescente — é retorno **negativo**.

Por quê? Nomes têm ~7 letras. Com **block_size = 16**, a imensa maioria das posições do contexto é **preenchimento** (.), e o modelo gasta capacidade processando padding em vez de sinal.

2. Somando a isso, os embeddings posicionais das posições distantes quase nunca são exercitados: recebem pouco gradiente, permanecem próximos da inicialização aleatória e injetam ruído.

A lição: o contexto deve ser dimensionado pelo **tamanho real do dado**. Contexto grande demais não é neutro — custa computação e qualidade. (No Capítulo 11, com prosa, **block_size = 128** faz sentido justamente porque o texto de verdade é longo.)

3. Dois custos que crescem de formas diferentes:

- **computação:** cresce com T^2 (a matriz de afinidades é $T \times T$)
- **parâmetros:** cresce só com o embedding posicional — de 11.103 para 11.779, quase nada

É o **oposto** do MLP do Capítulo 3, onde os parâmetros cresciam linearmente com o contexto. A atenção troca custo de parâmetros por custo de computação.

E6 — Inspeccionando os pesos

Solução em `e6_inspecionar_atencao.py`.

O achado principal: boa parte do peso cai nos tokens de **preenchimento** (.), não nas letras. Isso **não** é bug — o softmax obriga os pesos a somarem 1, então quando o modelo não precisa trazer informação de nenhuma posição específica, ele "estaciona" o peso numa posição inofensiva. O fenômeno tem nome na literatura de LLMs: **attention sink**.

E7 — Multi-head attention

Cabeças	head_size	Parâmetros	Treino	Validação
1	52	11.363	2,1589	2,1517
2	26	14.119	2,0752	2,0643
4	13	14.119	2,0463	2,0367

1. Várias cabeças pequenas ganham. De 1 para 4 cabeças a validação melhora 0,115 — um ganho grande para este capítulo.

Note que 2 e 4 cabeças têm **exatamente os mesmos 14.119 parâmetros**: `head_size = n_embd // n_head`, então o total de pesos das cabeças é constante. A melhoria de 2 para 4 vem **só da organização**, não de capacidade extra.

A versão de 1 cabeça tem menos parâmetros (11.363) porque não tem a projeção de saída. A comparação limpa é entre 2 e 4 cabeças.

2. Por que várias ajudam? Uma cabeça aprende **um** critério de "onde olhar". Várias aprendem vários — uma pode seguir a vogal anterior, outra o começo da palavra, outra a última consoante. Como as saídas são concatenadas e projetadas, o modelo combina esses critérios.

3. É exatamente a peça que abre o Capítulo 5.

Gabarito — Capítulo 05

Respostas discursivas. Os **números** vêm de `gabarito.py`.

Orçamento: 2.500 passos por configuração (a apostila usa 15.000).

E1 — Leitura de código

1. Por que `x = x + self.sa(self.ln1(x))` e não `x = self.sa(self.ln1(x))`? A soma é a **conexão residual**. Ela muda duas coisas:

- **na ida:** a sub-camada não precisa produzir a representação inteira — só uma **correção** ao que já estava lá. Aprender um ajuste é mais fácil que reconstruir tudo.
- **na volta:** a derivada de uma soma **distribui** o gradiente igualmente. O `x +` cria um caminho pelo qual o gradiente flui até as primeiras camadas **sem ser multiplicado por nada**.

2. Por que `head_size = n_embd // n_head`? Para que a concatenação das cabeças volte a ter `n_embd`. Com `n_embd = 64` e `n_head = 4`, são 4 cabeças de 16 que concatenam de volta em 64 — **quatro cabeças pequenas custam o mesmo que uma grande**. Se cada cabeça tivesse `head_size = n_embd`, o custo seria `n_head` vezes maior.

3. **Atenção vs feedforward:** A **atenção comunica** — move informação entre posições. O **feedforward computa** — processa cada posição isoladamente, sem trocar nada. Um bloco faz as duas coisas: as posições conversam, depois cada uma pensa sozinha sobre o que ouviu.

E2 — Sem as conexões residuais

Solução em `e2_ablacoes.py`:

Configuração	Loss validação
3 blocos, residual ON	1,9029
3 blocos, residual OFF	2,1971 (+0,294)
6 blocos, residual ON	1,8865
6 blocos, residual OFF	2,7728 (+0,886)

A penalidade **triplica** ao dobrar a profundidade. E o mais revelador: **sem** residuais, ir de 3 para 6 blocos **piora** o modelo (2,197 -> 2,773); **com** residuais, melhora (1,903 -> 1,887).

Sem conexões residuais, profundidade atrapalha. Com elas, ajuda.

E3 — Sem LayerNorm

Blocos	lr	LayerNorm	Validação
3	1e-3	ON	1,9365
3	1e-3	OFF	1,9318
3	3e-3	ON	1,9504
3	3e-3	OFF	2,0104
8	1e-3	ON	1,9228
8	1e-3	OFF	1,9181
8	3e-3	ON	1,9709
8	3e-3	OFF	DIVERGIU

Penalidade de remover a LayerNorm:

Profundidade	$lr = 1e-3$	$lr = 3e-3$
3 blocos	-0,0047	+0,0600
8 blocos	-0,0047	divergiu

1 e 2. A resposta não é "LayerNorm sempre ajuda". Leia a tabela de penalidades:

- Com $lr = 1e-3$, remover a LayerNorm dá **-0,0047 nas duas profundidades** — ela é dispensável, e até marginalmente prejudicial, tanto com 3 quanto com 8 blocos.
- Com $lr = 3e-3$, remover custa +0,06 com 3 blocos e **destrói o treino** com 8.

Não é a profundidade que cria a necessidade — é a learning rate. A profundidade **amplifica a falha**: o mesmo lr que apenas degrada um modelo de 3 blocos aniquila um de 8.

3. Faz sentido pela teoria da Seção 4 da apostila: a LayerNorm impede que o erro de escala se acumule. Com passos pequenos as ativações não saem de escala, e não há o que corrigir. Com passos grandes elas saem — e aí o número de camadas decide se o estrago é recuperável.

A lição, que se repete no curso: uma peça pode ser **correta e necessária em geral**, mas dispensável na configuração específica que você está testando. Isso não a torna inútil — torna o seu teste insuficiente para julgá-la.

E4 — Profundidade e número de cabeças

<code>n_layer</code>	<code>n_head</code>	Parâmetros	Validação
1	4	53.915	1,9818
3	4	153.499	1,9365
6	4	302.875	(ver saída)

<code>n_layer</code>	<code>n_head</code>	Parâmetros	Validação
3	1	153.499	1,9618
3	4	153.499	1,9365
3	8	153.499	1,9227

1 e 2. Mais profundidade ajuda, com retorno decrescente.

3. Mudar `n_head` não muda o número de parâmetros — repare que as três linhas da segunda tabela têm exatamente **153.499**. Como `head_size = n_embd // n_head`, o total de pesos das cabeças é constante. O que muda é **como esses pesos são organizados**: quantos softmaxes independentes existem.

E5 — Uma cabeça grande vs várias pequenas

<code>n_head</code>	<code>head_size</code>	Parâmetros	Validação
1	64	153.499	1,9618
8	8	153.499	1,9227
64	1	153.499	1,9137

1 e 2. Várias cabeças pequenas ganham, e com **exatamente os mesmos parâmetros**. A melhora vem só da organização: cada cabeça se especializa numa relação diferente, e a projeção combina o que todas trouxeram.

3. Esta resposta não saiu como eu previa.

Eu esperava um limite: com `n_head = 64` cada cabeça tem dimensão 1, e um produto escalar de vetores de dimensão 1 é só a multiplicação de dois números — pareceria pobre demais para expressar afinidade.

A medição diz o contrário: 64 cabeças foi o melhor dos três.

Por que o limite não aparece aqui? Porque a tarefa é simples (nomes, contexto 8). Sessenta e quatro padrões de atenção escalares, combinados pela projeção, dão conta. O custo de cada cabeça ser pobre é compensado pela quantidade.

Na prática os modelos usam `head_size` entre 32 e 128 — mas por razões que este experimento **não exercita**: tarefas complexas onde cada cabeça precisa comparar representações ricas, e eficiência de hardware (cabeças muito pequenas geram matmuls pequenas, que a GPU odeia — ver Capítulo 8).

Vale saber a regra prática E saber por que ela existe. Uma regra da literatura pode não se reproduzir na sua escala.

E6 — Dropout

Dropout	Treino	Validação	Gap
0,0	1,9438	1,9365	-0,0073
0,1	1,9517	1,9448	-0,0069
0,3	1,9774	1,9681	-0,0093

1. O dropout atrapalha aqui, e de forma monotônica. Com 64 mil nomes, treino e validação já andam juntos — o gap é praticamente nulo. Sem overfitting para combater, o dropout só remove capacidade.

É exatamente a mesma lição do weight decay no Capítulo 7, e o padrão é o mesmo: **treino e validação pioram juntos, e o gap não muda**. Regularização que não está resolvendo nada.

2. Ele ajudaria com **poucos dados** — releia o E5 do Capítulo 3 (155 nomes: treino 0,80 contra validação 6,51).

3. Por que desligar na avaliação? Porque com dropout ativo você estaria medindo um modelo **aleatoriamente mutilado** — a loss viria pior e ruidosa, sem significar nada. O `model.eval()` desliga o dropout (e ajusta a BatchNorm, quando existe).

E7 — Contando os parâmetros

Com `n_embd = 64`, `n_head = 4`, `n_layer = 3`, `block_size = 8`, `vocab = 27`:

Componente	Total
<code>token_emb</code> (27 × 64)	1.728
<code>pos_emb</code> (8 × 64)	512
por bloco (qkv + proj + ff + 2 LayerNorm)	49.792

× 3 blocos	149.376
LayerNorm final	128
<code>lm_head</code> ($64 \times 27 + 27$)	1.755
Total	153.499

1 e 2. A fórmula reproduz exatamente o número que o código informa.

3. Quem domina: os blocos somam 149.376 de 153.499 — **97%**. E dentro de cada bloco, o **feedforward** é o maior pedaço, por causa da expansão 4×.

Consequências para escalar:

- Dobrar `n_embd` **quadruplica** o custo dos blocos (todas as matrizes são `ne × ne` ou `ne × 4ne`).
- Dobrar `n_layer` apenas **dobra**.

É por isso que modelos grandes crescem mais em profundidade do que em largura — e por que `n_embd` é a decisão de arquitetura mais cara.

Gabarito — Capítulo 06

Respostas discursivas. Os **números** vêm de `gabarito.py` (roda em ~2 minutos, sem treinar rede nenhuma).

E1 — Unicode e UTF-8

1. Quantos bytes ocupa "pão"?

```
'pao' : 3 caracteres, 3 bytes -> [112, 97, 111]
'pão' : 3 caracteres, 4 bytes -> [112, 195, 163, 111]
```

Mesmo número de **caracteres**, um byte a mais. O **ã** ocupa **2 bytes** em UTF-8 (**195, 163**), enquanto **a** ocupa 1.

2. `ord("ç")` vale 231 — isso significa que cabe em 1 byte?

Não, e este é o erro clássico do capítulo. 231 é o **code point** (a identidade Unicode do caractere), não a codificação. Em UTF-8, todo code point acima de 127 usa 2 bytes ou mais — **ç** vira **[195, 167]**.

Confundir code point com byte leva a bugs sutis: você conta 3 caracteres e aloca 3 bytes.

3. Por que começar pelos bytes elimina o "desconhecido"?

Existem exatamente **256** valores de byte, e todos estão no vocabulário base. Qualquer texto — de qualquer idioma, mais emoji, mais código-fonte — é uma sequência de bytes, logo é sempre representável. Não há como aparecer algo "fora do vocabulário".

E2 — Tamanho do vocabulário

Vocabulário	Fusões	Tokens (treino)	Compressão	Ganho
300	44	95.043	1,578x	—
512	256	66.936	2,241x	+0,663
1024	768	52.965	2,832x	+0,591

1 e 2. A compressão melhora, com **retorno decrescente**: as primeiras 256 fusões valem +0,663 de compressão; as 512 seguintes valem só +0,591. As fusões mais frequentes são aprendidas primeiro, e as seguintes cobrem casos cada vez mais raros.

3. O custo de um vocabulário maior não está no tokenizador — está no modelo. Duas matrizes crescem com `vocab_size`:

- a tabela de embeddings: `vocab_size × n_embd`

- a camada de saída (`lm_head`): `n_embd × vocab_size`

Dobrar o vocabulário dobra as duas. É um trade-off direto: **sequências mais curtas (bom) contra modelo maior (custo)**. Modelos reais usam entre 32 mil e 200 mil tokens, e essa escolha é uma decisão de arquitetura, não um detalhe.

E3 — As primeiras fusões

```
256: 'an' 261: 'il'
257: 'a\n' 262: 'on\n'
258: 'e\n' 263: 'ar'
259: 'el' 264: 'o\n'
260: 'on' 265: 'er'
```

1. Por que ('a', 'n') é a primeira? Porque `an` é a sequência de duas letras mais frequente em nomes brasileiros: `ana`, `alessandra`, `fernanda`, `luana`, `antonio`...

2. Por que tantas fusões terminam em `\n`? Quatro das dez primeiras contêm quebra de linha. O motivo é o **formato do arquivo**: um nome por linha. A quebra de linha faz parte do padrão de **terminação** dos nomes, e o tokenizador está literalmente aprendendo "como um nome acaba".

Isso revela algo importante: o tokenizador aprende o **formato do arquivo**, não só a língua. Se você mudasse para nomes separados por vírgula, ele aprenderia `,` no lugar. Formatação é dado.

3. Os tokens mais longos:

```
'ilson\n', 'erson\n', 'isson\n', 'ilene\n', 'ilton\n', 'ilane\n',
'laine\n', 'iane\n', 'ison\n', 'iele\n', 'iana\n', 'aldo\n', ...
```

São **sufixos produtivos de nomes brasileiros**. O algoritmo não tem nenhuma noção de morfologia — ele só conta pares. Estatística pura virando estrutura linguística.

E4 — A ordem das fusões importa

Aplicando as fusões numa ordem arbitrária em vez da ordem de aprendizado:

Texto	Ordem correta	Ordem errada	Round-trip
<code>maria eduarda</code>	7	8	[OK]
<code>joao vinicius</code>	9	9	[OK]
<code>ana beatriz de souza</code>	15	15	[OK]
20.000 caracteres	9.137	10.041	+9,89%

1. O **round-trip continua valendo**. O **decode** desfaz qualquer sequência de fusões válidas, então o texto volta igual. A ordem errada **não quebra** o tokenizador — só o deixa pior.

2. A **compressão piora ~10%** em texto de tamanho razoável. Significativo, ainda que não catastrófico.

Repare no contraste entre as duas partes da tabela — e é a lição metodológica do exercício. Nos três textos curtos, dois deram **exatamente o mesmo** número de tokens. Quem medisse só neles concluiria que "a ordem quase não importa". Só com volume o efeito de ~10% aparece de forma confiável. **Amostra pequena esconde efeito real**.

3. **Por que a regra é obrigatória mesmo assim?** Dois motivos:

- Uma fusão tardia pode usar um token criado por uma anterior; aplicá-la antes desmonta a cadeia.
- Sem ordem fixa, o mesmo texto poderia produzir tokens diferentes em execuções diferentes. Um tokenizador precisa ser **determinístico** — senão o modelo recebe entradas inconsistentes.

E5 — O imposto do português

Solução em `e5_bpe_portugues.py`. Resumo: um BPE do **mesmo tamanho** treinado em português com acentos aprende `'ação '`, `'ção '`, `'não '`, `'são '` como tokens únicos, e gasta **53% menos tokens** (64 contra 135 em três frases).

E6 — Tokens fora do domínio

Texto	Bytes	Tokens	Compressão	Round-trip
nomes (mesmo domínio)	2.000	900	2,22x	[OK]
frase em português	60	50	1,20x	[OK]
japonês + emoji	17	17	1,00x	[OK]
código Python	33	29	1,14x	[OK]

1. Fora do domínio a compressão desaba para perto de 1,00x: nenhuma das fusões aprendidas se aplica, então cada byte vira um token.

2. Mas o **round-trip continua True em todos os casos** — e é essa a garantia que importa. O tokenizador **não comprime** o que não conhece, mas **nunca falha**. Japonês, emoji e código-fonte são todos representáveis, porque o vocabulário base são os 256 bytes.

3. Um **tokenizador de palavras** receberia uma palavra japonesa e não teria entrada nenhuma para ela — precisaria emitir `<UNK>`, **perdendo a informação de forma irreversível**. É a diferença entre "comprime mal" e "não representa".

E7 — Integrando com o modelo

Este exercício é mais de raciocínio que de medição.

1. O que muda em `vocab_size` e nos parâmetros? De 27 para 512 (ou 1024). As duas matrizes ligadas ao vocabulário crescem na mesma proporção: embeddings (`vocab_size × n_embd`) e `lm_head` (`n_embd × vocab_size`). Com o modelo do Capítulo 5 (`n_embd = 64`), isso vai de ~3,5 mil para ~65 mil parâmetros só nessas duas.

2. Quanto texto cabe no mesmo `block_size`? Com compressão de 2,24x, uma janela de 8 tokens passa a cobrir ~18 caracteres em vez de 8. **O contexto efetivo mais que dobra sem custo nenhum** — é o principal ganho prático da tokenização.

3. A loss é comparável? Não, e entender por quê é o ponto do exercício.

A cross-entropy mede a incerteza **por token**. Prever entre 27 opções e prever entre 512 são tarefas de dificuldade diferente: o piso de um chute uniforme passa de $\ln(27) = 3,30$ para $\ln(512) = 6,24$. Uma loss de 2,0 significa coisas muito diferentes nos dois casos.

Para comparar de forma justa, converte-se para **bits por caractere** (BPC):

```
BPC = loss_por_token / ln(2) / caracteres_por_token
```

Essa métrica é independente do tokenizador — e é por isso que é usada na literatura para comparar modelos com vocabulários diferentes. É exatamente a armadilha que o Capítulo 11 aponta ao aposentar o benchmark de 1,776.

Gabarito — Capítulo 07

Respostas discursivas. Os **números** vêm de `gabarito.py`.

Orçamento: 2.500 passos por configuração (a apostila usa 15.000). Onde essa redução muda a conclusão, está dito.

Aviso geral deste gabarito: quatro das oito respostas contrariam a expectativa — inclusive a minha, quando escrevi os exercícios. Todas foram corrigidas pela medição.

E1 — Leitura de código

1. O que a correção de viés faz? `m` e `v` começam em **zero**. No primeiro passo, $m = (1 - \beta_1) \cdot g = 0,1 \cdot g$ — dez vezes menor que o gradiente real. As médias móveis **subestimam** no início. Dividir por $(1 - \beta_1^t)$ compensa exatamente isso: no passo 1 o divisor é `0,1`, multiplicando `m` por 10.

Ela importa mais no início porque é lá que o viés é grande. Conforme `t` cresce, $\beta_1^t \rightarrow 0$, o divisor tende a 1 e a correção **desaparece sozinha**.

2. Weight decay somado ao gradiente vs aplicado ao parâmetro: No Adam original, o termo de decay entrava no gradiente e depois passava pela **divisão por** $\sqrt{v}$. Isso distorce a regularização: parâmetros com gradiente grande recebiam *menos* decay, sem nenhuma razão. O AdamW aplica o decay direto no parâmetro, fora do caminho adaptativo — daí o "W" de *decoupled*.

3. Por que $\sqrt{\text{fan_in}}$ e não `fan_in`? Um neurônio soma `fan_in` produtos independentes. A **variância** de uma soma de `n` termos independentes cresce com `n`, logo o **desvio padrão** cresce com $\sqrt{n}$. Como queremos controlar o desvio padrão, dividimos por $\sqrt{\text{fan_in}}$.

E2 — O warmup é necessário?

Warmup	Validação	Norma média (100 primeiros passos)
0	1,9198	1,223
50	1,9211	1,351
200	1,9219	1,498
500	1,9226	1,645

1. Neste modelo o warmup não ajuda — e piora de forma monotônica. Gastar 500 dos 2.500 passos com learning rate reduzida é desperdiçar 20% do orçamento num modelo que não tem problema de estabilidade.

2. Cuidado com a métrica — e eu escolhi a errada.

A norma dos gradientes nos primeiros passos **umenta** com o warmup (1,223 -> 1,645). Seria tentador ler isso como "o warmup deixa o treino mais instável". Não é.

Com warmup a learning rate começa minúscula, então o modelo demora mais para sair da região de inicialização — onde a loss é alta e os gradientes são **naturalmente maiores**. A norma alta mede **lentidão**, não instabilidade. A métrica não testava o que eu queria testar.

3. Então por que o warmup existe? Porque nos primeiros passos **m** e **v** do Adam quase não têm informação. Em modelos **grandes**, com batches grandes, um passo ruim no início pode levar a loss a um regime do qual ela não se recupera.

O warmup é um seguro contra um risco que cresce com a escala. Nesta escala, ele só custa. Isso não o torna errado — torna este modelo insuficiente para julgá-lo.

E3 — Calibrando o gradient clipping

Norma do gradiente sem clipping: **média 1,324, máxima 2,427**.

Clip	Validação	% de passos cortados
0,1	1,9206	100,0%
1,0	1,9205	99,6%
3,0	1,9219	0,0%
100,0	1,9219	0,0%

1. Com **clip = 3,0** (acima da norma típica de 1,32) **nada** é cortado — o comportamento correto de uma rede de segurança que não é acionada.

2. Com **clip = 0,1**, **100% dos passos são cortados**: isso deixa de ser clipping e vira **normalização** do gradiente — o erro documentado na Seção 5 da apostila.

Mas seja honesto com o número: **aqui isso não prejudicou** (1,9206 contra 1,9219 sem clipping — até marginalmente melhor). Normalizar todo gradiente é um algoritmo **diferente**, não necessariamente pior. Ele só não é o que você pensa que está rodando.

O problema de configurar errado nem sempre é perder desempenho. Às vezes é **não saber qual algoritmo você está usando** — e então não conseguir explicar o resultado.

3. Com **clip = 100** nada é cortado e a loss é idêntica à de não ter clipping. Conclusão honesta: **neste modelo o clipping é dispensável**. Não há picos. Ele existe para o caso patológico.

4. O clipping altera só o **tamanho** do gradiente, não a **direção**: todos os componentes são multiplicados pelo mesmo fator. A informação de "para onde ir" é preservada.

E4 — O ganho certo para a GELU

Desvio padrão das ativações na 8ª camada:

Ganho	tanh	ReLU	GELU
1,000	0,2483	0,0493	0,0068
1,414 ($\sqrt{2}$)	0,5515	0,7879	0,5393
1,500	0,5892	1,2635	1,0508
1,667 (5/3)	0,6472	2,9400	2,7308
2,000	0,7253	12,6212	12,2773

1. O ganho que mantém o desvio ~ 1 para GELU é $\approx 1,49$.

2. Fica **entre** o da ReLU (1,414) e o da tanh (1,667), mais perto da ReLU. Faz sentido: a GELU é uma versão suave da ReLU e deixa passar um pouco menos de sinal, precisando de um ganho ligeiramente maior.

3. O PyTorch não tem entrada para GELU:

```
torch.nn.init.calculate_gain('relu') = 1.4142
torch.nn.init.calculate_gain('gelu') -> ValueError
```

Na prática quase ninguém ajusta esse ganho para GELU — porque modelos modernos usam **LayerNorm**, que re-normaliza a cada bloco e torna o valor exato bem menos crítico (a apostila mede isso na Seção 2).

E5 — A curva da learning rate

Solução em `e5_curva_lr.py`. Curva em U, com mínimo em **3e-3** naquele orçamento — maior que o **1e-3** da apostila, porque **a melhor learning rate depende do orçamento de passos**.

E6 — AdamW vs SGD no modelo de verdade

Otimizador	Lr	Validação
AdamW	1e-3	1,9219
SGD	1e-3	2,6488
SGD	1e-2	2,2738

SGD	1e-1	2,0090
SGD	5e-1	1,9294
SGD + momentum	1e-2	2,0105
SGD + momentum	1e-1	1,9213

1. Com a **mesma** learning rate (1e-3), o SGD fica muito atrás: 2,65 contra 1,92. Um passo bom para o AdamW é minúsculo para o SGD.

2. Mas **ajustando a learning rate, o SGD+momentum EMPATA com o AdamW** (1,9213 contra 1,9219). O SGD puro fica logo atrás (1,9294).

Ou seja: neste modelo o AdamW **não é magicamente superior** — ele é superior **com a learning rate padrão**. A grande vantagem prática do Adam não é chegar mais longe, é chegar lá **sem que você precise caçar a learning rate certa**. Isso vale muito quando cada tentativa custa horas de treino.

3. O modelo tem parâmetros de escalas muito diferentes (embeddings, pesos de atenção, ganhos de LayerNorm, vieses). Uma única learning rate não serve para todos — é o experimento do [optimizers.py](#). O Adam normaliza o passo por parâmetro e escapa desse aperto.

E7 — Por que o weight decay atrapalhou

Weight decay	Treino	Validação	Gap
0,00	1,9243	1,9207	-0,0036
0,01	1,9256	1,9219	-0,0037
0,10	1,9382	1,9334	-0,0048
0,50	2,0015	1,9938	-0,0077

1 e 2. Olhe as três colunas juntas. Aumentar o weight decay piora **treino e validação juntos**, e o **gap entre eles quase não muda**. Esse padrão é a assinatura de que a regularização **não está resolvendo overfitting** — ela está apenas removendo capacidade.

Se houvesse overfitting, o esperado seria: treino piora, validação **melhora**, gap diminui. Não é o que acontece.

3. Com gap praticamente nulo no baseline (-0,004), **não há overfitting para combater**. Weight decay é remédio para uma doença que este modelo não tem.

4. Ele ajudaria com **poucos dados** — releia o E5 do Capítulo 3: com 155 nomes, treino 0,80 contra validação 6,51. Lá o gap é enorme, e a regularização teria o que fazer.

E8 — Outros agendamentos

Agendamento	Validação
constante	1,9449
cosseno	1,9219
linear	1,9206
degraus	1,9404

Diferença entre o melhor e o pior: **0,0243**.

1 e 2. Decair ganha de não decair — mas os agendamentos não são equivalentes entre si. O linear e o cosseno ficam praticamente empatados e claramente à frente; os **degraus** ficam quase tão ruins quanto o constante.

Faz sentido: com apenas 2.500 passos, o primeiro degrau (em 50%) demora demais a chegar. Agendamentos por degrau foram feitos para treinos longos, em que cada patamar tem tempo de render.

E o cosseno ser o padrão da área é mais **convenção** do que superioridade medida — pelo menos nesta escala, o linear empata ou ganha.

3. O problema de depender de `max_steps`: o cosseno precisa saber o total de passos **de antemão**. Se você quiser continuar um treino já terminado, a curva já chegou ao fim e não há como esticá-la sem estragar o formato — a learning rate ficaria presa no mínimo.

É um incômodo real, e existem alternativas: o **WSD** (*warmup-stable-decay*) mantém a learning rate constante por tempo indeterminado e só decai no fim, permitindo decidir depois quando parar.

Gabarito — Capítulo 08

Respostas discursivas. Os **números** vêm de `gabarito.py`.

Para exercitar a GPU, rode com o Python que tem o `torch-directml`:
`C:\dml312\Scripts\python.exe solucoes/gabarito.py`

(!) **Seus números não vão bater com os daqui, e está tudo bem.** Veja a nota sobre variabilidade no E2.

E1 — Latência vs vazão

1. Por que a GPU perde numa matmul de 128×128? Porque há um **custo fixo** por operação — lançar o kernel, coordenar o dispositivo, sincronizar — que não depende do tamanho do trabalho. Numa matmul minúscula, esse custo fixo é maior que o cálculo em si. A CPU faz a conta e devolve; a GPU passa a maior parte do tempo se organizando.

2. Por que a CPU fica em ~340 GFLOP/s e a GPU vai de 167 a 5.500? A CPU **satura cedo**: ela tem poucos núcleos e já os usa quase todos mesmo em matrizes pequenas. A GPU tem **milhares** de núcleos, e só os ocupa quando há trabalho para todos. Em matrizes pequenas, a maioria fica ociosa.

3. Uma tarefa com muitos `if` e desvios roda melhor em quê? Em **CPU**. Núcleos de GPU executam em grupos que compartilham a mesma instrução; quando o código diverge (uns entram no `if`, outros não), o hardware precisa executar os dois caminhos em sequência e descartar o que não vale — perdendo boa parte do paralelismo. A CPU tem previsão de desvio e execução fora de ordem justamente para esse tipo de código.

E2 — Encontre o seu ponto de virada

Uma execução (AMD Radeon RX 7600 via DirectML):

Tamanho	CPU (ms)	GPU (ms)	Speedup	GFLOP/s GPU
128	0,05	0,03	1,52x	136
256	0,18	0,04	4,51x	857
512	1,36	0,10	13,89x	2.745
1024	7,47	0,40	18,55x	5.332
2048	62,94	3,72	16,92x	4.619

1 e 2. A GPU ganha a partir de algumas centenas, e o speedup cresce até estabilizar em torno de 15-18x.

(!) Sobre a variabilidade — e um erro que eu cometi

Estes números não batem com os da apostila (que mediu 0,75x em 128 e 15,26x em 1024). E não porque um dos dois esteja errado.

Ao preparar este gabarito eu rodei a mesma medição três vezes e obtive **1,08x, 1,52x e 2,09x** para 128×128. A variação vinha de **outros processos disputando a CPU** — o gabarito de outro capítulo estava treinando ao fundo enquanto eu media.

Medição de tempo é sensível a:

- carga da máquina (o meu erro)
- estado térmico e frequência do processador
- até se você multiplica `a @ b` ou `a @ a` — a segunda tem melhor localidade de cache e deixa a CPU mais rápida

O que é estável, e o que você deve verificar:

- a **forma** da curva: speedup baixo nos tamanhos pequenos, crescendo até estabilizar
- a **ordem de grandeza** do ganho máximo (uma a duas dezenas de vezes)
- o fato de que a **CPU satura** e a **GPU escala**

Se quiser números comparáveis, feche tudo e rode com a máquina ociosa. É irônico e apropriado que o capítulo sobre medir corretamente tenha me pegado justamente aqui.

3. O pico de GFLOP/s medido fica bem abaixo da especificação da placa. Isso é normal: a especificação supõe uso perfeito das unidades, precisão reduzida e nenhum gargalo de memória. Os capítulos 9 e 10 atacam exatamente essa diferença.

E3 — A armadilha do `.item()`

Medição	ms/passo
sem ler a loss	1,18
lendo <code>.item()</code> a cada passo	1,57 (+33%)

1 e 2. Um terço a mais de tempo, e a causa são **duas coisas** que o `.item()` faz:

- **transfere** um valor da GPU para a CPU
- para poder fazê-lo, **espera** a GPU terminar tudo o que estava na fila

A segunda é a cara. Ela destrói o paralelismo entre CPU e GPU: normalmente a CPU vai enfileirando o próximo passo enquanto a GPU trabalha no atual; com o `.item()`, ela para e espera.

3. Como registrar sem pagar o preço:

- registre a cada N passos (100, por exemplo) — você precisa da **curva**, não de todos os pontos
- ou acumule os valores num tensor **na GPU** e leia só no fim

E4 — Tamanho do batch

Batch	ms/passo	ms por exemplo
32	0,149	0,00466
128	0,174	0,00136
512	0,183	0,00036
2048	0,477	0,00023

1 e 2. O tempo por passo cresce **muito menos** que proporcionalmente: batch 64x maior custa só 3x mais tempo. Por isso o tempo **por exemplo** cai 20x. É a mesma lição da Seção 4 da apostila.

3. O limite é a memória da placa — você verá um erro de alocação.

4. Cuidado com a conclusão, e este é o ponto do exercício. Batch maior processa mais exemplos por segundo, mas **cada passo continua sendo um passo de gradiente**. Se você dobrar o batch sem ajustar a learning rate, o treino faz metade do progresso por exemplo visto. Releia o E5 do Capítulo 7 e a Seção 6 do Capítulo 10.

E5 — Meça errado de propósito

Medição	Tempo	"Speedup"
GPU sem drenar	0,054 ms	230,6x
GPU com drenar	0,460 ms	26,9x

A medição errada exagera em ~9x (e numa das execuções, em 18x).

1. Sem drenar, a GPU parece absurdamente rápida — porque estamos medindo o tempo de **enfileirar** a operação, não o de executá-la. O Python devolve o controle imediatamente.

2. Por que a CPU não é afetada? Porque nela a execução é **síncrona**: quando a linha termina, a conta terminou. Não existe fila.

3. Como detectar que a medição está contaminada:

- speedups que **não crescem de forma monotônica** com o tamanho

- valores fisicamente implausíveis (centenas de vezes)
- tempos que não mudam quando o trabalho aumenta

E6 — Operações que caem de volta na CPU

Solução em `e6_fallback.py`:

Otimizador	GPU (ms/ passo)	Speedup	Fallback
AdamW	75,2	2,65x	<code>aten::lerp.Scalar_out</code>
SGD + momentum	32,7	5,94x	nenhum
SGD puro	30,9	6,23x	nenhum

Trocar o otimizador **mais que dobra** o ganho. Aquela única operação custava ~42 ms por passo — mais da metade do tempo total. E não aparece como erro: só como lentidão.

E7 — Quando vale a pena mudar para GPU?

Juntando os números da Seção 7 da apostila:

Modelo	Parâmetros	Speedup
pequeno (o do curso)	153 mil	0,30x — a GPU perde
médio	3,2 M	2,65x
grande	18,9 M	6,82x

1. O ponto de equilíbrio fica entre 153 mil e 3,2 milhões de parâmetros — mais perto do limite inferior, já que 3,2 M já dá 2,65x.

2. O custo não é só de execução. Instalar um ambiente separado, descobrir operações não suportadas (o `lerp` do E6) e depurar travamentos consomem **horas**. Para um treino de 6 minutos, não compensa; para um de 6 horas, compensa muito. A conta é de tempo total, não de tempo de GPU.

3. Para o modelo pequeno deste curso, a recomendação é CPU — e essa é a resposta contra-intuitiva do capítulo. "Usar GPU" não é automaticamente certo: é uma decisão que depende da escala e que **se mede**.

Gabarito — Capítulo 09

Respostas discursivas. Os **números** vêm de **gabarito.py**, que roda na CPU em segundos. O **E6** depende de GPU — a resposta está abaixo, com os números que a apostila mediu.

E1 — Contas com bits

1. Qual formato representa **100000**? E **1e-9**?

- **100000** -> só o **bf16**. O fp16 estoura em 65.504.
- **1e-9** -> só o **bf16**. O fp16 zera abaixo de $\sim 6e-8$ (contando com subnormais).

Os dois casos têm a mesma causa: os 8 bits de expoente do bf16 contra os 5 do fp16.

2. Quantos valores distintos entre 1 e 2?

Com **m** bits de mantissa, exatamente 2^m valores. Então:

- bf16 (7 bits) -> **128** valores entre 1 e 2
- fp16 (10 bits) -> **1.024** valores
- fp32 (23 bits) -> $\sim 8,4$ milhões

3. Por que dobrar os bits de mantissa não dobra a precisão? Porque a relação é **exponencial**, não linear: cada bit a mais **dobra** o número de valores representáveis. Ir de 7 para 14 bits multiplica a resolução por $2^7 = 128$, não por 2.

E2 — Achando os limites na mão

```
fp16: estoura em  $2^{15} = 3,277e+04$  (finfo.max = 6,550e+04)
      zera em  $2^{-25} = 2,980e-08$  (finfo.tiny = 6,104e-05)
bf16: estoura em  $2^{127} = 1,701e+38$  (finfo.max = 3,390e+38)
      zera em  $2^{-134} = 4,592e-41$  (finfo.tiny = 1,175e-38)
```

1. O expoente máximo bate com o **finfo.max** — a potência de 2 exata fica um pouco abaixo do máximo, que usa a mantissa cheia ($1,111\dots 2 \times 2^{15}$).

2. Por que dá para ir muito abaixo do **.tiny antes de zerar?** Por causa dos números **subnormais**. Abaixo do menor valor normal, o formato abre mão de precisão para continuar representando valores cada vez menores — usa a mantissa como se o expoente estivesse travado no mínimo. É uma "rampa de saída" gradual em vez de um corte seco. Repare na distância: o fp16 tem **.tiny = 6,1e-05** mas só zera em **3,0e-08**, três ordens de grandeza abaixo.

3. O bf16 estoura e zera em expoentes muito maiores porque tem 8 bits de expoente — o mesmo alcance do fp32.

E3 — O epsilon na prática

x	$1+x$ em fp32	$1+x$ em fp16	$1+x$ em bf16
1e-1	1,100000	1,099609	1,101562
1e-2	1,010000	1,009766	1,007812
1e-3	1,001000	1,000977	1,000000
1e-4	1,000100	1,000000	1,000000

(Os valores em negrito são somas que **não mudaram nada** — o x foi arredondado para fora.)

1. Em fp16 a soma deixa de ter efeito por volta de $x = 1e-4$ (epsilon = $9,77e-04$).
2. Em bf16 o limite é **maior** (epsilon = $7,81e-03$): ele já falha em $1e-3$. Tem 3 bits menos de mantissa, então distingue menos casas decimais.
3. **É exatamente por isso que os pesos mestres ficam em fp32.** Uma atualização típica de treino tem ordem de $1e-4$ a $1e-6$. Somada a um peso de ordem 1 em 16 bits, ela é arredondada para fora e o peso **não muda** — como a apostila mede (o peso continua em $1,000000$ depois de 100 atualizações).

E4 — A janela do loss scaling

Pesos	Escala	% zerados	infs	Situação
0,02	1	50,3%	0	perde gradiente
0,02	1.024	0,1%	0	ok
0,02	2^{20}	0,0%	2	overflow
0,50	1	0,1%	0	ok
0,50	1.024	0,0%	0	ok
0,50	2^{20}	0,0%	1	overflow

1 e 2. Leia a tabela com cuidado — o efeito não é o que parece.

Com pesos maiores (0,50), o underflow praticamente **desaparece**: com escala 1, os zerados caem de 50,3% para 0,1%. O limite **inferior** da janela desce muito.

Mas o limite **superior** quase não se mexe: os dois casos começam a estourar por volta de 2^{20} . Então a janela **não se desloca — ela alarga**.

E faz sentido: o *underflow* depende da magnitude dos gradientes (que muda com os pesos), enquanto o *overflow* depende do teto do formato (65.504), que é **fixo**. Só o piso se move.

3. O scaler dinâmico continua se justificando, mas por um motivo mais preciso: a magnitude dos gradientes **cai** conforme o modelo converge. Uma escala fixa escolhida no início pode ficar pequena demais depois, reintroduzindo *underflow* justamente na fase de ajuste fino.

E5 — Melhorando o GradScaler

Fator	Escala final	Passos descartados
1,01	70.966	0 / 40
2,00	524.288	4 / 40
16,00	65.536	6 / 40

1. Fator grande (16) reage rápido mas passa do ponto: sobe demais, estoura, desce demais — e descarta 50% mais passos. Fator **pequeno** (1,01) é estável (zero descartes) mas demora a se ajustar quando a magnitude dos gradientes muda.

2. Por que um piso é útil? Ele evita que uma sequência de overflows derrube a escala a um valor tão baixo que **reintroduza underflow**. Sem piso, o scaler pode se auto-sabotar ao reagir de forma exagerada a um pico isolado.

3. Por que `growth_interval = 2000`? Porque errar para cima custa **um passo descartado**, mas errar com **frequência** faz o treino descartar passos o tempo todo. É melhor subir raramente e ficar estável do que perseguir o ótimo e viver descartando.

E6 — Seu hardware acelera 16 bits? (precisa de GPU)

Medido na máquina desta apostila (AMD Radeon RX 7600 via DirectML), matmul 1024×1024:

Dispositivo	fp32	fp16	Ganho
CPU	5,35 ms	1.951 ms	~0,003x
Radeon	0,40 ms	0,41 ms	0,98x

1. Nesta máquina, nenhum ganho.

2. Isso significa que precisão reduzida é inútil? Não — e o exercício existe para essa distinção. São dois benefícios independentes:

- **memória:** garantido pela aritmética (metade dos bytes), vale em qualquer hardware
- **velocidade:** depende de o hardware e o backend terem unidades de 16 bits

Aqui o segundo não aparece. Numa NVIDIA com tensor cores, aparece — tipicamente 2x a 8x.

3. Se você tem NVIDIA, compare o ganho medido com a especificação da placa. Ele raramente chega ao pico teórico, porque nem toda operação do modelo é matmul.

E7 — Treino em precisão mista

Na versão CPU do `gabarito.py`, um problema de brinquedo treinado 400 passos:

Modo	Loss final
fp32	0,0463
bf16	0,0463
fp16 (sem scaler)	0,0463

1 e 3. O autocast com **bf16** chega à mesma loss do fp32 — não estraga o treino. Esperado: o bf16 tem o alcance do fp32.

2. Aqui o fp16 sem scaler também deu idêntico — e isso exige honestidade sobre o que o teste não mostra.

Não significa que loss scaling seja dispensável. Significa que **este problema não provoca underflow**. Compare com o `loss_scaling.py` da apostila: lá os pesos são deliberadamente pequenos (`p.mul_(0.02)`), os gradientes ficam na casa de `1e-8`, e **50,3% deles zeram**. Aqui os pesos são os da inicialização padrão, os gradientes são saudáveis, e nada zera.

A lição metodológica: um teste que passa não prova que a proteção é desnecessária — prova que o teste não exercita o caso que ela protege. É a mesma armadilha do E2 do Capítulo 4, com a máscara causal.

Modelos profundos de verdade têm gradientes muito menores nas camadas iniciais, e é lá que o fp16 sem scaler quebra.

4. Por que a economia de memória não chega aos 50%? Porque a cópia **mestra** dos pesos e o estado do otimizador (`m` e `v` do AdamW) continuam em fp32. Só as ativações e as matmuls usam 16 bits.

Gabarito — Capítulo 10

Respostas discursivas. Os **números** vêm de `gabarito.py`, medidos numa máquina de 12 núcleos.

```
python solucoes/gabarito.py
```

O E3 roda em **subprocesso com timeout**, porque o objetivo literal daquele exercício é fazer o programa travar — e um gabarito que trava para sempre não serve para ninguém.

E1 — Entendendo o coletivo

1. Quatro processos, o rank **i** tem o valor **i**.

Operação	Resultado em cada rank
<code>all_reduce</code> com SUM	$0+1+2+3 = 6$
<code>all_reduce</code> com MAX	3

O ponto do "all": **todos** terminam com o mesmo valor. Não é o rank 0 que fica com a soma — é todo mundo.

2. As quatro operações.

Operação	Quem fica com o resultado
<code>reduce</code>	um rank (o destino)
<code>all_reduce</code>	todos
<code>gather</code>	um rank recebe a lista completa
<code>all_gather</code>	todos recebem a lista completa

`reduce/all_reduce` **combinam** os valores (soma, máximo). `gather/all_gather` **empilham** sem combinar: cada rank fica com os N tensores separados.

3. Por que o **broadcast** não serve para sincronizar gradientes.

Porque o **broadcast** copia o valor de **um** rank para os demais — e nenhum rank tem o valor certo para transmitir. Cada um calculou o gradiente do **seu** pedaço do batch; o gradiente correto é a **média dos quatro**, que não existe em lugar nenhum antes de alguém somá-los.

Usar **broadcast** do rank 0 equivaleria a jogar fora os dados dos outros três processos — todo o trabalho deles seria descartado. É exatamente o que a soma do `all_reduce` evita.

E2 — Escalando o número de processos

Tempo de um `all_reduce`, melhor de 3 rodadas, **duas passadas independentes** (12 núcleos):

Processos	10 mil	1 milhão	10 milhões
2	0,54 / 0,56 ms	21,0 / 15,3 ms	264,9 / 280,2 ms
4	2,35 / 1,83 ms	9,8 / 8,7 ms	93,6 / 105,8 ms
8	5,81 / 5,70 ms	13,3 / 12,7 ms	174,2 / 177,7 ms

Reprodutibilidade entre passadas: **1,02x a 1,38x**. O efeito discutido abaixo é de **2,7x** — bem acima do ruído.

1. Não há uma resposta só — ela depende do tamanho do tensor, e é essa a descoberta.

- **10 mil elementos:** o tempo **crece ~10x** de 2 para 8 processos.
- **10 milhões:** o tempo **cai quase 3x** de 2 para 4 processos.

Sim, *cai*. Com mais processos, o all-reduce do tensor grande fica **mais rápido**.

Eu tinha escrito que o tempo sempre cresce com N, apoiado na propriedade do anel (cada processo troca ~2× o tamanho do tensor, independentemente de N). Essa propriedade é verdadeira — e não é a que domina.

A explicação é a mesma dicotomia do [Capítulo 8, latência vs vazão](#):

Tamanho do tensor	O que domina	Efeito de mais processos
Tensor pequeno	latência dos N-1 saltos do anel	mais saltos -> pior
Tensor grande	vazão : transferir e somar 40 MB	trabalho dividido -> melhor

No caso grande, o anel divide o trabalho em pedaços de `tamanho/N`. Com N=2 cada processo lida com 20 MB por etapa; com N=4, com 10 MB. Pedaços menores cabem melhor na cache, e a **soma** — que é trabalho real, não só transferência — se espalha por mais núcleos.

2. No esquema ingênuo (todos -> rank 0 -> todos), o rank 0 receberia `(N-1) × tamanho`: o tempo cresceria **linearmente** com N, e ele viraria um gargalo cada vez pior. E o ganho observado em N=4 seria **impossível** — o rank 0 é um só, e não paraleliza.

3. Onde os processos passam a competir por CPU. Nesta máquina de 12 núcleos, N=8 perde para N=4 nas colunas grandes: o tempo piora por **contenção**, não por comunicação. Numa máquina só, "mais processos" tem um teto físico, e ele fica perto do número de núcleos.

(!) **Cuidado ao generalizar.** Tudo isto foi medido em *uma* máquina, com gloo em CPU. Num cluster de verdade, com GPUs e rede dedicada, o equilíbrio entre latência e vazão é outro — mas a **pergunta a**

E3 — Provoque um deadlock

Este exercício me pegou. Vale ler a previsão antes do resultado.

A previsão (errada)

A explicação clássica do deadlock em `send/recv` é o **buffer de socket**: o sistema operacional aceita mensagens pequenas e devolve o controle imediatamente, sem esperar ninguém receber. Sob essa teoria, tensores pequenos passariam por acidente e só os grandes travariam — o que faria deste um bug clássico de "passa no teste, quebra em produção".

Eu escrevi essa resposta antes de medir. O próprio enunciado original do exercício dava essa dica.

A medição

Tensor	Alternância par/ímpar	Resultado
1 elemento	sim	terminou
1 elemento	não	TRAVOU
100 elementos	sim	terminou
100 elementos	não	TRAVOU
5 milhões	sim	terminou
5 milhões	não	TRAVOU

Trava sempre. Até com **um único elemento**. O `dist.send` do gloo só retorna quando o `recv` correspondente foi postado do outro lado — não existe tamanho pequeno o bastante para escapar.

A explicação do buffer de socket vale para **sockets crus e para MPI**. Não vale para o gloo, que fez outra escolha de projeto.

O que aprender com isso

Sobre o gloo: a escolha dele é boa. Um deadlock que acontece *sempre* é muito melhor que um que só aparece em produção com tensores grandes. O gloo trocou "às vezes funciona" por "nunca funciona", e **falhar de forma determinística é um recurso, não um defeito** — o bug aparece no primeiro teste que você rodar, na sua máquina, com dados de brinquedo.

Sobre você (e sobre mim). Eu tinha um modelo mental correto e o apliquei a uma implementação que não o segue. O modelo estava certo *em geral* e errado *naquele caso* — e nenhuma quantidade de raciocínio teria revelado isso. Só medir revela.

É o mesmo padrão do E2 do Capítulo 4 e do E3 do Capítulo 5.

E note o modo de falha: não há exceção, não há mensagem. O programa simplesmente para — exatamente como aconteceu no desenvolvimento deste capítulo, com o hostname que resolvia para um IP público (Seção 8 da apostila).

E4 — A loss que engana

Solução em `e4_loss_correta.py`.

1. Por que os ranks imprimem losses diferentes se os pesos são idênticos? Porque cada rank calcula a loss no **seu** micro-batch, e os micro-batches são diferentes. Os *pesos* são idênticos (o DDP garante isso sincronizando os gradientes); os *dados* não.

2. Com `all_reduce` da loss dividido por `world_size`, os valores passam a bater entre os ranks — porque agora todos estão reportando a mesma quantidade: a loss média sobre o batch global.

3. O que aconteceria com a curva se você registrasse só o rank 0. Ela ficaria **mais ruidosa** do que o treino realmente é. A loss do rank 0 é uma amostra de batch 64; a loss global é uma amostra de batch 256. Quatro vezes mais dados, metade do ruído.

O perigo prático: você olha a curva serrilhada, conclui que o treino está instável, e sai mexendo na learning rate para consertar um problema que **existe só na medição**.

E5 — Batch efetivo e learning rate

300 passos, batch **local** fixo em 64:

Processos	Batch efetivo	lr	Loss global
1	64	<code>1e-3</code>	2,0095
2	128	<code>1e-3</code>	1,9417
4	256	<code>1e-3</code>	1,8494
2	128	<code>1,4e-3</code> ($\times\sqrt{2}$)	1,9155
4	256	<code>2,0e-3</code> ($\times\sqrt{4}$)	1,7846

1. Com o batch local fixo, mais processos = batch efetivo maior. Como o número de **passos** é o mesmo, o modelo vê mais dados — mas dá o mesmo número de **atualizações**. A loss melhora, porque cada gradiente é menos ruidoso.

2. Sim, ajustar a lr melhora ainda mais. Escalar por $\sqrt{\text{world_size}}$ recuperou parte da diferença nos dois casos (1,9417 -> 1,9155 e 1,8494 -> 1,7846). Gradiente menos ruidoso tolera — e pede — passo maior.

3. Por que "mais GPUs" pode deixar o treino mais lento em número de passos. Porque você processa mais exemplos por passo, mas continua andando com o **mesmo tamanho de passo**. Mais dados por atualização, mesmo número de atualizações: é preciso mais passos para chegar ao mesmo lugar. O ganho está em tempo de parede por passo, não em progresso por passo — e só se materializa se você ajustar a learning rate junto.

É a mesma armadilha do [E4 do Capítulo 8](#) (batch maior é mais eficiente por exemplo, mas não é grátis do ponto de vista da otimização).

E6 — Meça o ZeRO

Estado do otimizador, por processo:

Otimizador	Processos	Normal	ZeRO-1	Redução
AdamW	2	8,54 MB	4,33 MB	2,0x
AdamW	4	8,54 MB	2,23 MB	3,8x
SGD sem momentum	2	0,00 MB	0,00 MB	—
SGD sem momentum	4	0,00 MB	0,00 MB	—

1. Sim, o estado por processo cai para $\sim 1/N$ — como a apostila mede com 4 processos.

2. E aqui está o ponto do exercício: com SGD sem momentum, o ZeRO-1 não economiza nada. Zero contra zero.

O motivo é direto: o SGD puro **não guarda estado nenhum** — ele usa o gradiente e descarta. Se o otimizador não guarda nada, não há o que fatiar. O ZeRO-1 economiza exatamente aquilo que o otimizador guarda.

(Os estágios 2 e 3, que fatiam **gradientes e pesos**, continuariam ajudando — eles não dependem do otimizador.)

3. Com bf16 nos pesos (Capítulo 9), a conta muda de forma interessante. Pesos e gradientes passam de 4 para 2 bytes por parâmetro, mas o estado do AdamW costuma ficar em fp32 por precisão. Com 8 processos:

Estratégia	Pesos	Gradientes	Estado	Total/GPU
DDP	2 GB	2 GB	8 GB	12 GB
ZeRO-1	2 GB	2 GB	1 GB	5 GB

O peso **relativo** do estado do otimizador **aumenta** quando os pesos encolhem — ou seja, precisão reduzida torna o ZeRO ainda mais valioso. As duas técnicas se reforçam.

E7 — Quando distribuir *não* compensa

Juntando os números medidos:

- tempo de cálculo de um passo (modelo pequeno, CPU, Capítulo 8): **~12,8 ms**
- all-reduce de ~150 mil parâmetros (0,6 MB): a coluna "10 mil" do E2, escalada — fica na casa de **alguns milissegundos**

1 e 2. Para o modelo pequeno deste curso, comunicação e cálculo ficam na **mesma ordem de grandeza**. Distribuir em 4 processos dividiria o cálculo por 4 mas acrescentaria comunicação a cada passo — ganho líquido pequeno ou negativo.

3. A regra geral:

Distribuir compensa quando **tempo de cálculo por passo >> tempo de comunicação por passo**

O cálculo cresce com o **tamanho do modelo** e com o **batch**. A comunicação cresce só com o tamanho do **modelo** — o all-reduce troca gradientes, e há um gradiente por parâmetro, não por exemplo.

Logo: **aumentar o batch melhora a razão de graça**. É por isso que treino distribuído de verdade usa batches enormes — não é só por velocidade, é para que a comunicação valha a pena.

E é a mesma conclusão contra-intuitiva do [E7 do Capítulo 8](#): para o modelo deste curso, a resposta certa é **não distribuir**.

Gabarito — Capítulo 11

Respostas discursivas. Os **números** vêm de `gabarito.py`.

```
bash python solucoes/gabarito.py
```

Sobre o orçamento de treino — leia antes dos números

O modelo da apostila leva **~18 minutos** por treino (3.000 passos). Este gabarito roda vários experimentos, então usa **400 passos**. A arquitetura é **idêntica** à da apostila (`n_embd=192`, 6 cabeças, 4 blocos, 2,2 M parâmetros) — só o número de passos muda.

Essa distinção importa. Reduzir passos é defensável para perguntas **comparativas**; trocar a arquitetura não seria, porque mudaria o objeto em estudo.

Mas "defensável" não é "seguro". A aposta implícita é que a **ordem** entre as configurações não depende do orçamento, mesmo que os valores absolutos dependam. Essa aposta **já tinha perdido duas vezes** neste curso:

Onde	Com orçamento curto	Com orçamento cheio
Cap. 3, E4	melhor <code>lr</code> = 1,0	melhor <code>lr</code> = 0,1
Cap. 7, E5	<code>3e-3</code> ganha	<code>1e-3</code> ganha

Nos dois casos a pergunta era sobre **dinâmica de otimização** — e o orçamento é justamente a variável que a dinâmica consome. Já as perguntas *deste* capítulo são **estruturais** (quanto contexto, quantas posições, quantos dados). Eu escrevi, aqui mesmo, que por isso elas *deveriam* ser estáveis.

E aí eu medi, e estava errado

`checagem_orcamento.py` repete o E4 com o triplo dos passos e compara os **rankings**:

Orçamento	Ranking (melhor -> pior)
400 passos	256 < 128 < 32
1.200 passos	128 < 256 < 32

O **ranking virou**. Com 400 passos, `block_size=256` parecia o melhor; com 1.200 ele perde para 128 (4,1270 contra 4,1649). O E4 não era estrutural o bastante para escapar.

Refeito com os **3.000 passos** da apostila, virou de novo — e o mesmo aconteceu com o E7:

Exercício	Com 400 passos	Com 3.000 passos
-----------	----------------	------------------

E4 (contexto)	256 < 128 < 32	32 < 128 < 256 (inverteu por completo)
E7 (mais obras)	6 < 8 < 4 < 11	11 < 8 < 6 < 4 (inverteu por completo)

Duas inversões totais, nos dois exercícios que testei. Por isso as respostas do E4 e do E7 vêm de `e4_orcamento_cheio.py` e `e7_orcamento_cheio.py` — cerca de uma hora de treino cada. Vale a hora: a alternativa era publicar respostas que a própria checagem do curso já desmentia.

E os outros exercícios deste capítulo? E1, E3 e E5 não dependem de treino (são conceituais, de tokenização e de contagem de previsões), então o orçamento não os afeta. O **E6** (*model collapse*) foi reverificado em 3.000 passos (`e6_orcamento_cheio.py`) e a conclusão **se manteve, doze vezes mais forte**: a degradação passou de +0,45 para **+5,33**.

Ou seja: dos três exercícios deste capítulo que dependem de treino, **dois inverteram e um se confirmou**. Não há como saber qual é qual sem medir — e essa é exatamente a razão de medir.

A regra que fica. "Esta pergunta é estrutural, logo o orçamento não importa" é uma hipótese, não um argumento. Rode a sua configuração com o triplo dos passos e veja se a ordem se mantém. Se virar, o orçamento é a variável que decide — e o resultado curto não responde nada.

E1 — Por que essa ordem?

1. Por que o tokenizador é treinado só no texto de treino?

Porque o BPE **aprende com os dados**: ele decide quais pares de bytes fundir contando frequências. Se ele vir o texto de validação, essas contagens incluem material que o modelo deveria não conhecer.

O que vazaria, concretamente: se `Memorial de Aires` entrasse no treino do tokenizador, ele criaria tokens para nomes e expressões daquele livro. Na hora de avaliar, o texto de validação ficaria **artificialmente mais barato de codificar** — menos tokens, cada um mais previsível — e a loss cairia sem que o modelo tivesse ficado melhor.

É um vazamento sutil porque o tokenizador não é "o modelo". Mas ele faz parte do **pipeline**, e tudo que toca o pipeline precisa respeitar a divisão.

2. Por que dividir por obra e não sorteando parágrafos?

Porque parágrafos da mesma obra **compartilham informação**. Um exemplo concreto: se um parágrafo de *Dom Casmurro* que menciona "José Dias" cair no treino e o parágrafo seguinte cair na validação, o modelo já viu o nome, o assento narrativo, o vocabulário da cena e até a construção da frase anterior. Ele acerta a validação por ter visto quase a mesma coisa — não por ter aprendido português.

Dividir por obra garante que a validação seja um texto que o modelo **nunca viu em nenhuma forma**. É a diferença entre "consegue continuar este livro" e "consegue escrever como Machado".

O E2 mede exatamente esse efeito.

3. Por que `uint16` e não `int64`?

Porque o vocabulário tem 1.024 entradas e cabe folgado em 16 bits (que aguentam 65.536). O `int64` guardaria os mesmos números em **8 bytes** em vez de 2:

Tipo	Bytes/token	621 mil tokens
<code>int64</code>	8	4,97 MB
<code>uint16</code>	2	1,24 MB

Quatro vezes menos espaço, e o ganho não é só de disco: é de **banda de memória**. Como o treino lê os dados por `memmap` a cada batch, um arquivo 4x menor significa 4x menos tráfego entre disco, cache e CPU. Em corpora de verdade — centenas de gigabytes — essa escolha decide se o treino é limitado pelo cálculo ou pela leitura dos dados.

(!) O limite é real: com vocabulário acima de 65.536, o `uint16` **estoura silenciosamente** (os índices dão a volta). Tokenizadores modernos usam 100 mil a 200 mil tokens e precisam de `uint32`.

E2 — A divisão errada

Solução em `e2_vazamento.py`.

E3 — O tokenizador é do domínio

1. Os 20 tokens mais longos aprendidos:

```
'José Dias ' | 'ima Justin' | 'que não ' | 'minha mã' | 'Capitú, '  
'os olhos ' | 'da minha ' | 'inha mã' | 'Capitú ' | 'José Di'  
'a minha ' | 'seminari' | 'ação, ' | 'almente ' | 'não me '  
'que era ' | 'Capitú' | 'ação ' | 'é que ' | 'primeir'
```

6 dos 20 contêm nome de personagem (`José Dias`, `Capitú`, `Justin[a]`). Vários outros são marcas do texto específico: `'minha mã[e]'`, `'seminari[o]'`, `'os olhos '` — o narrador de *Dom Casmurro* falando da mãe, do seminário e dos olhos de ressaca.

Ninguém programou isso. O BPE só contou pares de bytes.

2. Isso é bom ou ruim? Depende de onde você vai usá-lo.

É **ótimo para este corpus e péssimo fora dele**. Um tokenizador que gasta um único token em `'José Dias '` comprime Machado maravilhosamente — e não tem nenhuma fusão útil para um artigo de medicina, onde cada `'hemoglobina'` seria fatiado em pedaços.

3. O BPE treinado em nomes, aplicado a Machado.

Mesmo trecho de prosa (109 bytes), dois BPEs de vocabulário 1.024:

BPE treinado em	Tokens	Chars/token
Machado	43	2,53
nomes (Cap. 6)	81	1,35

1,88x mais tokens para dizer a mesma coisa. O BPE de nomes aprendeu terminações como 'ilson' e 'erson', que quase não aparecem em texto corrido — e não aprendeu nada sobre que, de ou ção.

O custo é direto: 1,88x mais tokens significa 1,88x mais posições de contexto gastas para o mesmo texto, e um treino proporcionalmente mais caro para o mesmo conteúdo.

Nota de método. A primeira versão deste gabarito comparava "81 tokens no trecho" (de um tokenizador) com "2,59 chars/token no corpus inteiro" (do outro). São **grandezas diferentes**, e a comparação parecia razoável sem ser. O número acima mede os dois no mesmo trecho.

E4 — Tamanho do contexto

Com os 3.000 passos da apostila (e4_orcamento_cheio.py):

block_size	Treino	Validação	Gap	minutos
32	3,1947	3,8305	0,64	4,1
128	2,7816	3,9241	1,14	16,7
256	2,7419	4,0136	1,27	38,8

1. Mais contexto PIORA a loss de validação neste corpus. O melhor block_size é 32 — o menor dos três.

Essa é a resposta oposta à que eu tinha escrito, e a história de como ela mudou é a parte mais útil do exercício:

Orçamento	Ranking (melhor -> pior)	Vencedor
400 passos	256 < 128 < 32	256
1.200 passos	128 < 256 < 32	128
3.000 passos	32 < 128 < 256	32

A ordem se **inverteu completamente** conforme o orçamento cresceu. Com 400 passos eu concluí "mais contexto ajuda"; no orçamento de verdade, mais contexto atrapalha.

Por que — olhe a coluna do gap

O contexto maior tem loss de **treino menor** (2,74 contra 3,19) e loss de **validação maior**. Isso é overfitting, e o gap cresce monotonicamente com o contexto: 0,64 -> 1,14 -> 1,27.

A causa é um detalhe do desenho do experimento que vale internalizar. Com o **número de passos fixo**, **block_size** maior significa **mais épocas sobre o mesmo corpus**:

block_size	Tokens vistos em 3.000 passos	Épocas sobre 621 mil tokens
32	3,1 M	~5
128	12,3 M	~20
256	24,6 M	~40

Quarenta passagens por um corpus de 621 mil tokens, com um modelo de 2,2 M parâmetros, é receita de memorização. O que a tabela mede não é só "quanto contexto ajuda" — é "quanto contexto ajuda **a esta razão entre dados e capacidade**".

Com 400 passos ninguém tinha épocas suficientes para memorizar, e aí o contexto maior só mostrava a sua vantagem. O overfitting só aparece quando você treina o bastante para ele aparecer.

E a comparação com o Capítulo 4 fica mais interessante

No [Capítulo 4](#), **block_size=16** era pior que 8 — e eu atribuí isso a nomes serem curtos. Aqui, com prosa, o contexto maior **também** perde. A explicação "nomes são curtos" era verdadeira mas insuficiente: o fator comum aos dois casos é **corpus pequeno demais para a capacidade do modelo**.

Contexto longo não é um bem em si. Ele é uma aposta: você gasta capacidade e épocas para poder olhar mais longe. A aposta paga quando há dados suficientes para sustentá-la. Os modelos de contexto enorme que você vê por aí são treinados em trilhões de tokens — não em 1,6 MB de Machado.

(!) **Uma consequência para a apostila.** O capítulo treina com **block_size=128**, que por esta medida não é o ótimo para a loss de validação. A escolha continua defensável por outro motivo: um modelo com contexto 32 **não consegue** condicionar em mais de 32 tokens na hora de gerar, por melhor que seja a sua loss média. Loss de validação mede previsão do próximo token, não coerência de texto longo. Mas é uma escolha que agora está medida, não presumida.

2. Dobrar o contexto quadruplica o tempo? Não — e a resposta surpreende.

Mudança	Contexto	Tempo (3.000 passos)	Se fosse linear	Se fosse quadrático
32 -> 128	4x	4,07x	4x	16x
128 -> 256	2x	2,32x	2x	4x

O crescimento é **quase linear**, apesar de a atenção ser $O(T^2)$. (A medição com 400 passos deu 4,13x e 2,06x — as duas concordam, e é o esperado: tempo *por passo* não depende de quantos passos você dá.)

O motivo: a atenção é **só uma parte** do custo. As camadas lineares — **qkv**, projeção, e o feedforward que tem 4x a largura do modelo — crescem **linearmente** com T , e neste tamanho elas dominam. O termo quadrático existe, mas só passa a mandar em contextos bem maiores.

É por isso que "atenção é quadrática" é verdade e é enganoso ao mesmo tempo: verdade sobre a fórmula, enganoso sobre onde o seu tempo está indo. Meça.

3. "Para prosa, o contexto maior ajuda mais do que ajudava para nomes. Por quê?"

A premissa da pergunta está errada, e o enunciado a colocou lá porque eu acreditava nela. Medido, o contexto maior não ajuda aqui — atrapalha.

O raciocínio que sustentava a premissa continua **correto e é insuficiente**: prosa realmente tem dependências longas (concordância, referência a personagens, estrutura de período), e nomes de 7 letras não têm nada disso. Existe, sim, informação útil a 200 tokens de distância em Machado.

O que falta ao raciocínio é a outra metade da conta. Poder usar contexto longo exige:

- 1. **informação útil lá atrás** — prosa tem, nomes não têm; e
- 2. **dados suficientes para aprender a usá-la sem memorizar o caminho.**

Este corpus atende ao item 1 e falha no item 2. O modelo tem contexto disponível e não tem exemplos bastantes para aprender a explorá-lo — então usa a capacidade extra para decorar o treino.

É o tipo de erro que este curso repete de propósito: uma explicação **verdadeira** que não é a **dominante**. A mesma coisa aconteceu no **E2 do Capítulo 10**, onde a propriedade do anel que eu citei era real mas não era o que mandava no tempo.

E5 — Prever em todas as posições

Modo	Treino	Validação	Previsões/batch	ms/passo
todas as posições	4,4455	4,6957	4.096	365,1
só a última	6,0319	6,0564	32	360,4

- 1. Com **batch_size=32** e **block_size=128**: **4.096** previsões por batch contra **32**. São **128x mais sinal de treino**.
- 2. **A diferença é enorme**: 4,70 contra 6,06 de loss de validação, com o mesmo orçamento de passos. A versão que prevê só na última posição recebe 128x menos informação por passo.
- 3. **E o custo é praticamente o mesmo** — 365 ms contra 360 ms.

Esse é o ponto do exercício. As duas versões processam as 128 posições de qualquer jeito; a única diferença é **quantas saídas da camada final entram na loss**. A versão "só a última" faz o cálculo inteiro e **joga fora 99% dele**.

128x mais sinal, custo igual. É o tipo de mudança que quase não existe em engenharia — normalmente se paga por ganho.

Os capítulos 3 a 7 usaram a versão ineficiente **de propósito**, porque ela mantinha a métrica comparável entre capítulos. A partir daqui, não há motivo para isso.

E6 — Dados sintéticos e *model collapse*

[OK] **Reverificado no orçamento cheio.** Este era o último exercício do capítulo apoiado em 400 passos, num capítulo onde o E4 e o E7 tiveram a conclusão **invertida** ao passar para 3.000. Eu tinha publicado a conclusão com uma justificativa — não uma medição — de que ela deveria sobreviver. `e6_orcamento_cheio.py` mediu:

Modelo	Treino	Validação real
A (corpus de Machado)	2,7816	3,9241
B (texto gerado pelo A)	0,1149	9,2588

Degradação de +5,33, contra +0,45 com 400 passos. Perplexidade de 50,6 para **10.496**. A conclusão não só se manteve como ficou **doze vezes mais forte** — e a justificativa que eu tinha dado (o argumento informacional não depende do orçamento) estava certa.

Os números da seção abaixo continuam sendo os de 400 passos, porque é o que o `gabarito.py` roda em poucos minutos. As conclusões valem nos dois orçamentos.

Modelo	Treino	Validação real
modelo A (corpus de Machado)	4,4455	4,6957
modelo B (60 mil tokens gerados pelo A)	4,3012	5,1453

1 e 2. O modelo B fica pior na validação real — degradação de **+0,4496**. O fenômeno tem nome na literatura: *model collapse*.

O detalhe que torna isso perigoso

Olhe a coluna de treino. A loss de treino do modelo B é **menor** que a do A (4,30 contra 4,45). Se você olhasse só a curva de treino, concluiria que o B está aprendendo melhor.

E no orçamento cheio o contraste fica grotesco: **0,1149 de treino contra 9,2588 de validação**. O modelo B decorou o texto sintético quase perfeitamente — loss de treino 24 vezes menor que a do A — enquanto ficava 2,4 vezes pior no texto real. É a demonstração mais nítida deste curso de que **uma curva de treino excelente pode acompanhar um modelo destruído**.

Não está. Texto gerado por um modelo é **mais previsível** que texto humano — menos vocabulário, menos construções raras, menos surpresa. Ficar bom em prever texto fácil não é ficar bom em prever Machado.

O colapso chega disfarçado de progresso. É por isso que a validação precisa vir de dados reais e intocados — o mesmo princípio do E1 e do E2 deste capítulo.

Por que acontece

A razão é informacional. O texto gerado por A é uma **amostra** da distribuição que A aprendeu — e amostrar **perde a cauda**. Padrões raros aparecem pouco ou não aparecem, e o B aprende uma versão ainda mais concentrada. Repetindo o ciclo, a diversidade colapsa.

Nenhum modelo pode aprender dos próprios dados mais do que já sabe. A geração não cria informação nova sobre o mundo.

3. Quando dados sintéticos ajudam de verdade: quando existe uma **fonte de verdade externa** para filtrar.

Domínio	O verificador
matemática	dá para conferir a resposta
código	dá para rodar os testes
jogos	dá para saber quem ganhou

Nesses casos o modelo gera muitas tentativas e um verificador seleciona as boas. A informação que entra vem do **verificador**, não do modelo — e por isso o ciclo não colapsa. É a base do que o [Capítulo 15](#) vai fazer.

E7 — Escalando o corpus

Versão do gabarito: frações do mesmo corpus

Corpus	Tokens	Treino	Validação	Gap
25%	155.283	4,3627	4,7601	0,3975
50%	310.567	4,4252	4,7330	0,3077

100%	621.134	4,4455	4,6957	0,2501
------	---------	--------	---------------	---------------

1 e 2. Mais dados melhoram a validação. Os ganhos são pequenos e da mesma ordem ao dobrar o corpus (0,027 e depois 0,037).

(!) **Não leia isto como saturação.** Estes números são de **400 passos**, e a seção seguinte mostra que nesse orçamento o modelo mal completa uma passada pelo corpus — não há épocas suficientes para o overfitting aparecer, que é justamente o mecanismo pelo qual mais dados ajudam. Com os 3.000 passos da apostila, o ganho é **muito maior e não satura**. Esta tabela serve para ver o mecanismo depressa, não para concluir sobre escala.

3. A lógica do Capítulo 3 vale em direção, não em magnitude.

O **gap** entre treino e validação encolhe monotonicamente (0,40 -> 0,31 -> 0,25), confirmando que parte do problema era memorização — exatamente como lá.

Mas compare a escala:

Capítulo	Mudança nos dados	Efeito no gap
Cap. 3	155 -> 64.000 nomes	5,7 -> ~0
Cap. 11	155 mil -> 621 mil tokens	0,40 -> 0,25

Lá o modelo tinha ~10 exemplos por parâmetro; aqui já tem centenas de milhares de tokens.

Eu ia escrever aqui que "melhorias ficam progressivamente mais caras, é a forma de toda curva de escala". A frase é verdadeira **em geral** e não descreve o que foi medido: no orçamento cheio o ganho não deu sinal de desacelerar. Ver a seção seguinte.

Versão literal: acrescentando obras de verdade

O enunciado pede para **acrescentar obras**. A lista completa de Machado no Gutenberg tem 12 (confirmado na API, não chutado) — o `prepare_data.py` usa 5. `e7_mais_obras.py` baixa as outras 7 e mede.

Duas decisões de método, que importam mais que o resultado:

- 1. O tokenizador fica fixo.** Usamos o `tokenizador.pkl` já treinado, sem retreinar. Se retreinássemos, mudaríamos **duas coisas ao mesmo tempo** (mais dados e outro tokenizador) e não saberíamos a qual atribuir a diferença. Custo honesto: o tokenizador fica levemente mal-adaptado às obras novas — é o preço de isolar a variável, e é o preço certo a pagar.
- 2. A validação não muda.** *Memorial de Aires* continua fora do treino. Sem isso as losses não seriam comparáveis entre configurações.

Os resultados, com os 3.000 passos da apostila

`e7_orcamento_cheio.py`:

Obras	Tokens	Treino	Validação	Gap
4	617.457	2,8302	3,9989	1,1687
6	812.973	2,9886	3,7763	0,7877
8	1.073.284	3,0770	3,7120	0,6350
11	1.427.186	3,1520	3,6712	0,5192

Perfeitamente monotônico nas três colunas, e cada uma conta um pedaço da mesma história:

- a **validação** melhora sem parar — mais dados, melhor generalização;
- o **treino piora** sem parar — corpus mais diverso é mais difícil de decorar;
- o **gap** despenca de 1,17 para 0,52 — que é a definição de menos overfitting.

1 e 2. Sim, acrescentar obras melhora, e não saturou dentro do que foi testado. Indo de 617 mil para 1,43 milhão de tokens, a validação cai 0,33. Não há sinal de platô — o que sugere que este modelo ainda está limitado por **dados**, não por capacidade.

A resposta com 400 passos era o oposto

Orçamento	Ranking (melhor -> pior)
400 passos	6 < 8 < 4 < 11 (o pior)
3.000 passos	11 (o melhor) < 8 < 6 < 4

Com o orçamento curto, a conclusão era "melhora até 6 obras e depois piora". Com o orçamento cheio, é "melhora sempre, monotonicamente". A inversão é **completa**.

E há uma lição a mais escondida aí. Eu tinha escrito uma hipótese específica para explicar por que 11 obras seria pior: *Poesias Completas* é o único livro em **verso**, e misturar poesia com prosa mudaria a distribuição. A hipótese era plausível, específica, e parecia **confirmada** pelos dados de 400 passos.

No orçamento cheio, 11 obras é a **melhor** configuração. O efeito regularizador de mais dados supera a diferença de gênero — e a minha explicação bonita estava explicando um artefato de orçamento.

Por que os dois orçamentos discordam. Com 400 passos, o modelo vê ~1,6 M de tokens: nem uma passada completa pelo corpus maior. Ninguém decora nada, e o único sinal que sobra é o de **distribuição** — daí a poesia atrapalhar. Com 3.000 passos ele vê ~12 M de tokens: 20 passadas pelo corpus pequeno contra 8,6 pelo grande. Aí o que domina é **overfitting**, e mais dados ganham com folga.

Note que o confundimento aponta na direção **oposta** à do E4: lá, a configuração "maior" fazia *mais* épocas; aqui, faz *menos*. É o mesmo mecanismo produzindo conclusões invertidas — e é por isso que a pergunta "quantas épocas cada configuração faz?" deveria vir antes de qualquer interpretação.

3. A lógica do Capítulo 3 vale, e agora com força. Lá, aumentar os dados de 155 para 64 mil nomes levou o gap de 5,7 para ~0. Aqui, dobrar o corpus leva o gap de 1,17 para 0,52. Direção idêntica, magnitude menor — e, ao contrário do que o experimento com frações do corpus sugeria, **ainda longe de saturar**.

Gabarito — Capítulo 12

Respostas discursivas. Os **números** vêm de `gabarito.py`.

```
bash python solucoes/gabarito.py
```

Os exercícios E2 e E3 introduzem os bugs **de propósito**, em subclasses, para que você veja o modo de falha sem editar o modelo bom.

E1 — O que dá e o que não dá para cachear

1. Por que **k** e **v** são cacheáveis e **q** não é.

k e **v** da posição t dependem só do token em t e da sua posição — e nada disso muda quando um token novo chega em $t+1$. São propriedades **do passado**, e o passado está fechado.

q é diferente por natureza: a cada passo há um token novo fazendo uma pergunta nova ao histórico. A query é a única coisa que muda de verdade a cada iteração. Cachear query não faria sentido — ela é usada uma vez e descartada.

2. Sem máscara causal, o cache continuaria válido? Não.

Com atenção bidirecional, a representação da posição 3 depende do token 7. Quando o token 8 chega, **todas** as representações anteriores mudam — o **k** e o **v** guardados ficam obsoletos.

É uma observação que vale guardar: **o KV-cache só existe porque o modelo é causal**. Modelos tipo BERT não têm KV-cache, e não é falta de otimização — é que a otimização não existe para eles. A restrição que parecia limitação (só olhar para trás) é o que torna a geração eficiente.

3. As contas.

Caminho	Posições processadas
Ingênuo	$1 + 2 + \dots + 128 = 8.256$
Com cache	128 (uma por token)

Descartado no caminho ingênuo: $1 - 128/8.256 = 98,4\%$.

E2 — Quebrando a posição de propósito

Trocando a posição absoluta por `torch.arange(T)`:

Verificação	Resultado
-------------	-----------

Levantou exceção?	não
Gerou texto?	sim, 81 tokens
Primeira divergência	token 4

```
referência : 'de vocês e vinham a vida.\n\n--Papae não ira a Deus que a convidasse...'
com o bug : 'de vocês\nde lerguamos justa e uma dez do mariamente o a um homem...'
```

1. Nenhuma exceção, nenhum NaN, nenhum aviso. O texto sai com a mesma aparência de sempre. É o pior tipo de bug: ele não avisa.

2. Por que a divergência começa no token 4, e não no 1.

Porque o **prefill** processa o prompt inteiro de uma vez, e ali `T == T_total` — então `arange(T)` por acaso dá as posições certas. O bug só se manifesta na fase de **decode**, quando passamos um token só e ele acha que está na posição 0.

Isso é instrutivo por si: o bug se esconde exatamente na fase que o teste rápido (gerar um tokenzinho e ver se sai algo) não exercita.

3. Conseguiria dizer qual está errado sem a referência? Não.

Os dois textos são igualmente ruins a olho nu — porque um modelo de 2,2 M parâmetros já escreve mal quando está **certo**. A degradação se esconde no ruído de base.

Numa otimização de inferência, **"parece bom" não é evidência de nada**. É por isso que o critério do capítulo é *saída idêntica*.

E3 — Quebrando a máscara de propósito

Aplicando a máscara também no decode:

Verificação	Resultado
Primeira divergência	token 3
Tokens distintos na saída	54 de 80

1. Eu previ repetição. Errado.

Ao escrever este gabarito eu afirmei que o texto "degenera em repetição, porque todo token passa a ser gerado a partir do mesmo contexto". A contagem desmente: 54 tokens distintos em 80. A amostragem continua estocástica — o que se perdeu foi o **contexto**, não a diversidade.

O que o modelo virou — medido, não suposto

O teste certo não é olhar o texto. É perguntar: *de que a previsão ainda depende?* Duas histórias com o **mesmo primeiro token** e 19 tokens do meio completamente diferentes:

Modelo	Logits idênticos?	Diferença máxima
com o bug	sim	0,00
correto	não	6,22

Bit a bit idênticos. O modelo passou a prever a partir de (primeiro token, token atual, posição) e mais nada.

Ele virou, literalmente, o modelo do Capítulo 1: um **bigrama**. Toda a maquinaria de atenção continua rodando, consumindo tempo, e não transporta informação nenhuma.

2. Por que só o primeiro token sobrevive.

No decode `T == 1`, então `tril[:1, :T_total]` seleciona a **primeira** linha da matriz triangular: `[1, 0, 0, ..., 0]`. Ela permite olhar apenas a posição 0 — daí o primeiro token continuar influenciando enquanto todo o resto desaparece.

3. Eu também previ que este bug seria mais fácil de notar. Errado de novo.

O raciocínio era que ele "falha de forma escandalosa". Compare os dois textos: são igualmente ruins.

A lição dos dois exercícios juntos. Em modelo pequeno, nenhum dos dois bugs se denuncia pela leitura. Um deles rebaixa um Transformer a um bigrama e **você não percebe olhando**. O teste de equivalência não é burocracia — é o único instrumento que funciona.

E note que em modelo grande a situação é pior, não melhor: um GPT de verdade com esses bugs ainda escreveria português fluente. A fluência vem da camada de saída; a coerência é que vem do contexto.

E4 — Meça o ganho

`benchmark_cache.py`, máquina ociosa:

Tokens	Ingênuo	Com cache	Speedup	ms/token ing.	ms/token cache
16	0,070 s	0,045 s	1,53x	4,3	2,8
32	0,122 s	0,085 s	1,44x	3,8	2,7
64	0,272 s	0,170 s	1,60x	4,3	2,7
128	0,906 s	0,469 s	1,93x	7,1	3,7

O número que contradiz a Seção 1 da apostila

A apostila mostra que o caminho ingênuo desperdiça **98,4%** das posições processadas. Seria natural esperar um ganho de dezenas de vezes.

O ganho medido é 1,93x.

Não é erro de medição nem cache mal implementado. A Seção 2 do mesmo benchmark explica:

Medição	Custo
Prefill de 64 tokens de uma vez	5,66 ms -> 0,09 ms por token
Decode de 1 token com cache	3,30 ms
Razão	37x

Processar uma *posição* custa 0,09 ms. Processar uma *chamada* custa ~3,3 ms. A diferença é **custo fixo**: laço Python, despacho do PyTorch, alocação de tensores, leitura dos pesos das 4 camadas.

E os dois caminhos fazem o **mesmo número de chamadas** — uma por token gerado. Ambos pagam $128 \times \sim 3,3 \text{ ms} \approx 420 \text{ ms}$ só de overhead. O cache elimina o trabalho *dentro* de cada chamada, que neste modelo é a menor parte da conta.

98% do cálculo eliminado, 1,93x de ganho. É a lição do [Capítulo 8](#) reaparecendo: otimizar o que não domina não acelera. O KV-cache é indispensável — mas o *ganho* que ele entrega depende de o cálculo ser o gargalo, e num modelo de 2,2 M parâmetros na CPU ele não é.

Onde o ganho aparece de verdade: **modelos grandes** (o trabalho por posição cresce), **contextos longos** (o desperdício quadrático cresce) e **GPU** (o custo fixo por chamada é diluído). Num 7B com contexto de milhares de tokens, a diferença é entre viável e inviável — mas isso é uma extrapolação, não algo medido aqui.

As respostas

1. O **ms/token** do ingênuo cresce, mas só com clareza no último ponto (4,3 -> 3,8 -> 4,3 -> **7,1**). Até 64 tokens fica praticamente plano: o custo fixo domina e o contexto ainda é curto. O do cache também sobe um pouco no fim (2,7 -> 3,7), pela leitura de um cache maior — ou seja, "constante" é aproximação, não fato.

2. O **speedup cresce, devagar e não de forma monotônica** (1,53 -> 1,44 -> 1,60 -> 1,93). A queda em 32 tokens está dentro do ruído. A tendência é de crescimento, pelo motivo certo: o custo do ingênuo cresce com o contexto e o do cache quase não.

3. **Para um único token o cache não ajuda** — é um prefill nos dois casos. Ele começa a pagar do segundo token em diante, e não há comprimento em que atrapalhe: a alocação do cache não aparece no relógio neste tamanho.

E5 — A conta de memória

1. A fórmula, conferida contra `bytes_do_cache()`:

```
2 (K e V) × n_layer × batch × n_head × T × head_size × bytes
```

Para o modelo do curso com `T=128`: **786.432 bytes** (768 KB) — manual e método batem.

2. Um 7B em bf16, contexto 8.192:

Grandeza	Valor
Cache por usuário	4,3 GB
Placa de 80 GB - 14 GB de pesos	66 GB livres
Usuários simultâneos	15

Quinze. Uma placa de topo de linha, um modelo que cabe folgado nela, e quinze conversas ao mesmo tempo.

3. A reescrita que muda a leitura.

Como `n_head × head_size = n_embd`:

```
2 × n_layer × batch × T × n_embd × bytes
```

O cache não depende de quantas cabeças você usa, nem do tamanho delas — depende da largura e da profundidade do modelo. Redistribuir `n_embd` entre mais ou menos cabeças não muda nada no custo de servir.

O que muda é **quebrar a simetria**: se as cabeças de Q forem muitas e as de K/V forem poucas, o produto `n_head_kv × head_size` fica menor que `n_embd`. É precisamente isso que MQA e GQA fazem — e é por isso que elas são a intervenção óbvia nesta fórmula.

E6 — Cache com batch

Modo	Tempo
16 sequências de 64 tokens em paralelo	0,53 s
16 sequências de 64 tokens separadas	4,78 s
ganho	9,1x

1. Nada muda no código. A dimensão de batch já está na forma do cache (`B`, `n_head`, `T`, `hs`) e todas as operações são em lote — bastou passar um prompt com B linhas. Que a mudança seja nula é

um bom sinal sobre a implementação.

2. O ganho é grande pela razão do [Capítulo 8](#): o decode é limitado por **memória**, não por cálculo. Ler os pesos custa o mesmo para 1 ou para 16 sequências, então o custo se dilui.

É por isso que serviço de inferência agrupa requisições de **usuários diferentes** no mesmo batch. Não é para economizar — é que a alternativa desperdiça quase tudo.

3. **Comprimentos diferentes são o problema de verdade.** Se uma sequência termina no token 10 e outra no 200, o batch inteiro roda até a mais longa acabar: as posições já terminadas gastam cálculo à toa e o cache delas continua ocupando memória.

Estratégia	Como funciona
Preenchimento com máscara	simples e desperdiçador
Continuous batching	retira a sequência pronta e põe outra da fila no lugar
Paged attention (vLLM)	aloca o cache em páginas, sem reservar o pior caso por sequência

E7 — Multi-query attention (desafio)

MQA improvisada sobre os pesos treinados (média das 6 cabeças de K/V):

Configuração	Loss de validação	Cache (T=128)
Multi-head original	3,9357	768 KB
MQA improvisada	5,2697 (+1,3339)	128 KB (6x menor)

1 e 2. O cache cai por um fator de **n_head** — 6x aqui, **32x** num 7B. É a maior economia disponível nesta fórmula.

3. **E a loss desaba.** +1,33 de loss é um modelo destruído, não degradado.

Não há surpresa: o modelo foi **treinado** com 6 cabeças de K/V independentes, e cada cabeça de Q aprendeu a perguntar para a **sua**. Substituir as seis por uma média destrói essa correspondência.

MQA não é uma otimização que se liga na hora de servir. É uma decisão de arquitetura. O modelo precisa nascer assim (ou passar por *uptraining* com dados). Llama 2 70B e Mistral usam GQA porque foram projetados com ela.

A lição geral vale além deste exercício, e fecha o capítulo:

"Economiza memória" e "dá para aplicar depois" são afirmações **independentes**. O KV-cache é gratuito porque **não muda a conta** — é a mesma matemática, reorganizada. A MQA não é, porque muda. Toda

vez que alguém oferecer uma otimização, a primeira pergunta é: *isso altera o resultado?*

Gabarito — Capítulo 13

Respostas discursivas. Os **números** vêm de `gabarito.py`.

```
bash python solucoes/gabarito.py
```

E1 — A aritmética

1. Tensor em `[-3, 3]`, simétrica de 8 bits.

```
escala = max|x| / 127 = 3/127 = 0,023622  
q(1,5) = round(1,5 / 0,023622) = round(63,5) = 64 (ou 63, conforme o  
desempate do round)  
recuperado = 64 × 0,023622 = 1,51181
```

Erro de 0,0118 — cerca de **0,8%** do valor, e no máximo meia escala (0,0118) para qualquer entrada. O erro máximo de quantização é sempre **metade do passo**.

2. Por que `[-127, 127]` e não `[-128, 127]`.

Para manter a **simetria**. Se usássemos -128, o intervalo representável seria assimétrico e o mapeamento $q = x/escala$ deixaria de ser simétrico em torno de zero: **+3** viraria 127 e **-3** viraria -128, valores com magnitudes diferentes.

Custa 1 nível em 256 — **0,4%** da resolução — e evita um caso especial em toda conta subsequente. É uma troca boa, e é o que PyTorch faz por padrão.

3. Tensor em `[10, 11]`.

Com simétrica, $escala = 11/127 = 0,0866$. Mas o *intervalo útil* dos dados tem largura 1, então cabem apenas $1/0,0866 \approx 12$ níveis — de 256 disponíveis. Os outros 244 representam valores entre -11 e +10, que nunca ocorrem.

Erro esperado: metade do passo sobre um valor típico de 10,5, ou seja $0,0433/10,5 \approx 0,4\%$. Parece pouco, mas a *resolução dentro do intervalo real* é péssima.

A assimétrica usaria $escala = (11-10)/255 = 0,0039$ — **22x mais fina** — e representaria o mesmo intervalo com todos os 256 níveis.

(!) Com a ressalva do E2: como `[10, 11]` **não contém o zero**, é preciso estender o intervalo para `[0, 11]`, e aí a escala vira $11/255 = 0,0431$. Ainda **2x melhor** que a simétrica, mas não 22x. A extensão custa caro justamente nos casos mais deslocados.

E2 — A armadilha do zero-point

Distribuição `randn(1000) + 5`, valores em `[1, 24 ; 8, 63]`:

Variante	Erro
simétrica	0,393%
assimétrica sem estender o zero	1,007% <- pior
assimétrica com estender o zero	0,192%

1. Com o bug, a simétrica ganha — o oposto do que a teoria diz. Esse é justamente o sintoma que denuncia o problema: quando um método que *deveria* ser melhor sai pior, há bug antes de haver descoberta.

2. O zero-point ideal é -170,7 e não cabe em `[-128, 127]`.

A razão é conceitual, não numérica: o zero-point é o *inteiro que representa o float 0,0*. Se os dados vão de 1,24 a 8,63, o zero está **fora** do intervalo — e representá-lo exigiria um inteiro que o tipo não tem.

3. A cadeia causal completa, e vale segui-la inteira:

```
dados em [1,24 ; 8,63], que não contêm o zero
-> zero-point ideal = qmin - xmin/escala cai fora de [-128, 127]
-> o clamp o move para -128
-> o mapeamento inteiro se desloca em relação ao pretendido
-> q = x/escala + zero estoura o teto para os valores grandes
-> 12 de 1000 valores saturam em +127 e perdem a informação
-> o erro medido dispara
```

A correção — estender o intervalo para conter o zero — é o que PyTorch, TFLite e ONNX fazem. Ela custa resolução e garante duas coisas: o zero-point cabe, e o float `0,0` tem um inteiro exato (o que importa para *padding* e máscaras).

E3 — A métrica que mente

Matriz 8×64 com uma linha 100x maior, quantização int8:

Métrica	Per-tensor	Per-channel
erro relativo global (norma)	1,48%	0,52%
... só nas 7 linhas normais	56,15%	0,60%
mediana do erro por elemento	100,00%	0,67%

E o número que resolve a questão: **65,4%** dos pesos das linhas normais viraram **zero exato**.

1. Por que os dois primeiros números são tão diferentes. O erro global é ~1,5%; o das linhas normais é ~56%. A norma global é dominada pela linha grande, que quantiza bem — ela tem valores grandes o bastante para usar toda a resolução disponível.

2. A conta. `||w||` soma **quadrados**. A linha 0 tem valores 100x maiores, logo contribui **10.000x** mais que cada uma das outras para o denominador. O denominador de `erro_relativo` é praticamente só ela; o numerador (o erro) está espalhado por toda a matriz. Resultado: o erro das linhas pequenas acaba dividido por um número que não tem nada a ver com elas.

3. Uma métrica que denuncia sem desagregar: a mediana do erro relativo por elemento.

```
((rec - orig).abs() / orig.abs()).median()
```

Ela não tem denominador global, então nenhum elemento pode esconder os outros. Na tabela acima ela marca **100%** — mais da metade dos pesos perdeu todo o seu valor.

Alternativa igualmente boa: **a fração de pesos que virou zero exato**. Ela transforma "degradação" em "apagamento", que é o que de fato aconteceu.

Isto vale muito além da quantização. Sempre que os dados forem heterogêneos em escala, uma média ponderada pela magnitude vai contar a história do subconjunto grande.

E4 — Onde fica o precipício

Bits	Erro no peso	Piora da loss	Perplexidade
fp32	—	—	51,3
8	0,69%	-0,0001	51,3
6	2,84%	+0,0021	51,4
4	12,55%	+0,0636	54,6
3	29,31%	+0,4657	81,7
2	80,84%	+3,5298	1.749,3

1. Uma não prevê a outra, e é o ponto do exercício.

O erro no peso cresce de forma **suave e regular** — dobra a cada bit. A piora da loss é **desprezível até 4 bits e depois dispara**. São curvas de formatos completamente diferentes.

A razão: a rede tem folga. Perturbações pequenas nos pesos são absorvidas — até deixarem de ser pequenas.

Corolário prático: **nunca escolha o número de bits olhando o erro de reconstrução**. Ele é fácil de medir e não responde à pergunta.

2. O joelho está entre 4 e 3 bits. A piora salta de +0,064 para +0,466 — **7x**. E de 3 para 2 o modelo é destruído: a perplexidade sai de 82 para **1.749**.

3. Para servir este modelo eu escolheria **int8**, e a justificativa precisa dos **dois** eixos:

- **qualidade:** de graça (a loss não muda na quarta casa)
- **tamanho:** 4x menor, o que ataca o gargalo estabelecido no Capítulo 12

int4 também é defensável — custa 0,06 de loss e dá 8x. A escolha entre os dois depende de quanta memória você precisa economizar. O que **não** é defensável é escolher por um eixo só.

E5 — Quantizando os embeddings também

Configuração	Tamanho	Loss	Custo
int8, só Linear	2,89 MB	3,9371	—
int8, + embeddings	2,20 MB	3,9371	+0,0000
int4, só Linear	1,90 MB	4,0008	—
int4, + embeddings	1,10 MB	4,0457	+0,0449

1. Em **int8** é literalmente de graça: 24% menor, loss idêntica até a quarta casa. Em int4 o custo aparece — +0,045, o que quase dobra a penalidade total do int4 (0,064 -> 0,109).

2. Por que a resposta não é "no que tem a maior fração".

Vale onde a fração é grande **o bastante para mover o total**. Num 7B, os embeddings são ~2% dos parâmetros: quantizá-los muda o tamanho em 2%, o que não compensa nem o risco de qualidade nem a complexidade. Aqui são 10%, e a economia de 24% é visível.

A pergunta é sempre "*quanto isso move o número que me importa*", não "*qual é maior*".

3. A **camada de saída merece cuidado extra**, por uma razão estrutural: ela produz os **logits**, e a softmax é sensível a diferenças pequenas entre eles. Um erro que seria inofensivo numa camada intermediária pode **reordenar** os tokens mais prováveis.

Muitos esquemas de produção deixam a camada de saída — e a de entrada — em precisão maior justamente por isso.

E6 — O que a quantização faz com a velocidade

Configuração	Gerar 64 tokens
float32	0,129 s
int8	0,184 s (0,70x)

1. O **float32** é mais rápido. A quantização, desta forma, **custa** tempo.

2. Onde o tempo vai. No **forward** da **LinearQuantizada**:

```
F.linear(x, desquantizar_simetrica(self.q, self.escala), self.bias)
```

A desquantização reconstrói a matriz inteira em **float32** — conversão de tipo mais multiplicação pela escala, sobre **todos** os pesos, a **cada** chamada. Depois disso a matmul é exatamente a mesma de antes. Trabalho extra, mesmo trabalho antigo.

3. O que precisaria mudar. Um kernel que multiplicasse **int8 × int8** acumulando em **int32**, sem nunca materializar a matriz em float. Não se faz em PyTorch puro porque o operador não existe — **F.linear** espera floats. É preciso descer para C++/CUDA, ou usar llama.cpp, bitsandbytes, ONNX Runtime, que já fizeram isso.

"Menor" e "mais rápido" são independentes. A primeira decorre da representação; a segunda exige que alguém escreva o kernel.

E7 — Quantização por grupos

Matriz 256×256 com as 32 primeiras colunas 50x maiores, tudo em **int4**:

Esquema	Erro global	Erro nas colunas normais	bits/peso reais
per-channel (1 escala/linha)	11,23%	100,00%	4,06
grupos de 128	10,51%	65,90%	4,12
grupos de 64	10,13%	38,57%	4,25
grupos de 32	9,93%	9,69%	4,50

Eu caí na armadilha do meu próprio E3

Na primeira versão deste exercício eu medi **só o erro global** e conclui que os grupos quase não valiam a pena: de 11,2% para 9,9%, contra 11% mais bits — praticamente empate.

Errado, e pelo motivo que o E3 acabou de ensinar. A norma global é dominada pelas 32 colunas outlier, que quantizam bem em qualquer esquema.

Olhando a coluna que importa — as **colunas normais, que são 87,5% da matriz** — o quadro é outro: o per-channel em int4 as **apaga por completo** (100% de erro), e grupos de 32 reduzem isso para 9,69%. **Dez vezes melhor, por 11% mais bits.**

1 e 2. Grupos menores reduzem o erro onde ele existe, porque cada escala cobre menos variação. Com G=32 o bloco de outliers cai inteiro num grupo só e **para de contaminar os demais** — que é

exatamente o objetivo.

3. A conta de bits por peso reais, que costuma ser esquecida:

```
bits_reais = bits + (bits_da_escala / G)
```

Com int4 e G=64, guardando a escala em fp16: $4 + 16/64 = 4,25$ bits por peso. Com G=32: **4,5 bits**. Ou seja, "int4" com grupos pequenos não é 4 bits — é até **12% mais**.

É esse compromisso que os nomes dos formatos GGUF expõem: Q4_0, Q4_K_M e afins diferem no tamanho do grupo e em quantos bits gastam com metadados. Escolher entre eles é escolher um ponto nesta curva — e a escolha só faz sentido se você medir o erro **onde ele está**.

Gabarito — Capítulo 14

Respostas discursivas. Os **números** vêm de `gabarito.py` e de `e2_quando_a_mascara_importa.py`.

```
bash python solucoes/gabarito.py
```

E1 — Tokens especiais e vocabulário

1. Por que um id novo, e não a string `###FIM###`.

Porque o texto do usuário pode conter a string. Se alguém escrever `###FIM###` no meio de uma pergunta, o seu parser corta ali — e o modelo, treinado a tratar aquilo como fronteira, obedece.

Um token especial é uma garantia **estrutural**: não existe sequência de caracteres que o tokenizador transforme no id 1026. A fronteira não pode ser falsificada pela entrada.

É a base da defesa contra *prompt injection* por delimitador. Quando você lê que um modelo "confundiu a instrução do sistema com o texto do usuário", quase sempre há uma fronteira que era texto quando deveria ser estrutura.

2. Quantos parâmetros novos, com `n_embd = 192`.

Matriz	C Parâmetros
tabela de embeddings	3 576 x 192
camada de saída (pesos)	3 576 x 192
camada de saída (bias)	3 3
total	1.155

Confirmado pelo código: 2.196.352 -> 2.197.507. Um aumento de **0,05%**.

3. Zeros e valores aleatórios grandes.

Zeros na camada de saída não são neutros. Um logit zero é um valor específico dentro de uma distribuição já treinada, e para um modelo convergido a maioria dos logits reais é *negativa* — então o token novo nasceria **mais provável** que muitos tokens legítimos. O modelo passaria os primeiros passos consertando isso.

Valores aleatórios grandes são piores: o token novo domina a softmax, a loss explode nos primeiros passos, e o gradiente que corrige isso perturba o resto da camada.

A **média** das linhas existentes evita os dois: o token novo nasce estatisticamente indistinguível dos outros e se diferencia conforme aprende.

E2 — Quando a máscara importa

A medição

Pedido/resposta	% de pedido	Com máscara	Sem máscara	Penalidade
24 / ~34	42%	3,9964	3,9898	-0,0066
64 / ~20	72%	3,9450	3,9586	+0,0136
104 / ~12	87%	3,9588	3,9752	+0,0165

1. A explicação padrão é que treinar no pedido "gasta capacidade". O que ela **não** diz, e deveria, é que a loss sem máscara é uma **média sobre as posições** — então o tamanho relativo do pedido decide quanto ele dilui o sinal da resposta. Toda a dependência está aí.

2. A penalidade aparece a partir de ~70% de pedido, e o sinal **inverte**: com pedido curto, mascarar é marginalmente pior.

Repetindo a configuração de pedido longo com **seis sementes**:

Semente	Com máscara	Sem máscara	Diferença
1337	3,9588	3,9752	+0,0165
42	3,9737	3,9796	+0,0058
2024	3,9389	3,9690	+0,0301
7	3,9537	3,9860	+0,0322
99	3,9607	3,9867	+0,0261
555	3,9536	3,9624	+0,0088

6 de 6 na mesma direção, média **+0,0199 ± 0,0112**.

3. Nulo e negativo pedem reações diferentes.

No caso de pedido curto o resultado foi **negativo**, não nulo: mascarar saiu *pior* (-0,0066). Um resultado nulo autorizaria "não detectei diferença"; um negativo consistente autorizaria "a recomendação está invertida aqui". Este é pequeno demais para a segunda afirmação — está dentro do que a semente move.

O erro de análise que quase enterrou o resultado

Com as três primeiras sementes eu comparei a diferença entre variantes (0,0175) com a variação da **mesma** variante entre sementes (0,0348) e concluí: *"o ruído supera o efeito"*.

O critério estava errado para o desenho. As duas variantes rodam com a **mesma semente** — é um experimento **pareado**, e nele a variação que a semente causa afeta os dois lados e **se cancela na diferença**.

Critério	Números	Veredito
não pareado	ruído 0,0348 > efeito 0,0199	"não estabelecido"
pareado	6/6 na mesma direção, média > desvio	estabelecido

Mesmos dados, conclusões opostas, decididas só pela estatística escolhida.

É o segundo caso do curso em que a **medição estava certa e a leitura não**. O outro é o [Capítulo 13](#), onde uma métrica global marcava 1,3% de erro enquanto 48% das linhas estavam destruídas.

E a magnitude

+0,0199 sobre uma loss de 3,95 é 0,5%. O efeito é real e pequeno. "Estatisticamente detectável" e "importante na prática" não são a mesma coisa, e este número é o primeiro sem ser o segundo — *nesta escala*. Em SFT real, com prompt de sistema longo e histórico de conversa, a proporção é muito mais desfavorável que 87%.

E3 — Dados de tamanho fixo

Com **TAM_RESPOSTA = 40** fixo, todos os 8.000 exemplos ficam com exatamente 66 tokens:

Modelo	Taxa de parada	Comprimento mediano
SFT (com máscara)	100%	40
SFT (sem máscara)	100%	40

1 e 2. A taxa de parada é 100% e não significa nada. A métrica que separa as duas versões é o **comprimento mediano**: cravado em 40, sem variância.

O modelo aprendeu a **contar até 40**, não a concluir. Era a única regra consistente nos dados — e ele a aprendeu perfeitamente.

Com a correção (resposta até o fim de frase), os comprimentos passam a variar de 39 a 82 tokens, 44 valores distintos, e a mediana medida vira 34 — próxima mas não igual à do treino, que é o que se espera de um modelo que está lendo o texto.

3. Regularidades acidentais num conjunto real:

Regularidade	O que o modelo aprende
toda resposta começa com "Claro!"	a dizer "Claro!"
respostas de um anotador são mais longas	o estilo daquele anotador
exemplos difíceis foram descartados na curadoria	a nunca dizer "não sei"
perguntas de código sempre vêm com bloco markdown	a formatar mesmo quando não cabe

O modelo aprende a regularidade que os seus dados **de fato contêm**, não a que você pretendia ensinar. Antes de treinar, procure o que é acidentalmente constante.

E4 — A learning rate do finetuning

400 passos, 8.000 exemplos:

lr	Loss na resposta	Taxa de parada	Loss no texto puro
3e-5	4,2448	0%	3,9517
3e-4	3,9749	97%	4,0372
1e-3	4,0181	100%	4,1464
(modelo-base)	—	0%	3,9104

1. Não são as três. Com **3e-5** a taxa de parada é **0%** — passos pequenos demais não chegam a instalar um comportamento que não existia; só ajustam o que já estava lá.

E a melhor loss está no **meio**, não num extremo. Learning rate boa não é a maior nem a menor.

2. Olhe a última coluna. Ela mede a loss no texto corrido do Capítulo 11, sem formato de instrução — a capacidade original do modelo. O modelo-base marca 3,9104, e a coluna se afasta **monotonicamente** conforme a learning rate cresce: 3,9517 -> 4,0372 -> 4,1464.

O modelo está trocando a competência antiga pela nova, e o câmbio piora com o tamanho do passo.

3. Catastrophic forgetting. O finetuning vê um conjunto pequeno e homogêneo, e o gradiente empurra **todos** os pesos na direção que serve àquele conjunto. Nada no objetivo preserva o que foi aprendido antes.

A única proteção embutida é dar passos pequenos e poucos. É por isso que a learning rate de finetuning é tipicamente 3 a 10 vezes menor que a do pré-treino — não é cautela, é o mecanismo.

Note que os dois eixos apontam para lados opostos, e o **3e-4** do capítulo cai onde eles se equilibram: melhor loss na tarefa nova, com metade do custo em esquecimento que o **1e-3** cobra.

E5 — Quantos exemplos bastam?

Exemplos	Loss na resposta	Taxa de parada
500	4,8662	100%
2.000	4,1922	100%
8.000	3,9749	97%

1. As duas métricas se separam, e essa é a resposta.

A **taxa de parada satura em 500** — já é 100%. O formato é barato de instalar: três tokens especiais e uma convenção de onde cada um entra.

A **loss não satura**: 4,8662 -> 4,1922 -> 3,9749, quase **0,9** de melhora.

São coisas diferentes: uma mede se o modelo respeita o **formato**, a outra se ele escreve uma resposta **boa**. Só a primeira é barata.

2. Por isso a comparação com o Capítulo 11 precisa ser dividida. Para o **formato**, a curva satura cedo — ao contrário de lá. Para a **qualidade** da resposta, a curva se parece com a de lá, porque a tarefa volta a ser modelar texto.

3. Resultados como o do **LIMA** ("mil exemplos bem escolhidos bastam") falam do primeiro eixo. Se o que você quer é instalar **comportamento** — formato, tom, recusa, uso de ferramenta — mil exemplos variados bastam mesmo, e a medição acima mostra por quê: é pouca informação a transmitir.

O que mil exemplos **não** comprem é capacidade de gerar conteúdo melhor. Essa vem do pré-treino, e nenhum SFT a substitui.

E6 — O *alignment tax*

Modelo	Loss no texto corrido do Cap. 11
modelo-base	3,9104
depois do SFT (3e-4)	4,0372 (+0,1268)

1 e 2. O SFT piorou a capacidade de modelar português comum em **+0,127** de loss. Não é catastrófico, e não é zero.

3. É o **alignment tax**: o custo, na competência original, de instalar um comportamento novo. Ele **não é inevitável**, e há três formas conhecidas de reduzi-lo:

Técnica	Como ataca
misturar dados de pré-treino no conjunto de SFT	o gradiente continua vendo texto comum
LoRA / congelar camadas	limita quanto os pesos originais podem se mover
Ir menor, menos passos	o que o E4 mede

Todas atacam a mesma causa: **nada no objetivo do SFT pede que o modelo lembre do que sabia.**

E7 — Conversa com vários turnos

1. A máscara passa a ter várias faixas — uma por resposta, em vez de uma só:

```
<|pedido|> A <|resposta|> B <|fim|> <|pedido|> C <|resposta|> D <|fim|>
\_ máscara \_/\_ treina \_/\_ máscara \_/\_ treina \_/\_
```

Todos os turnos do usuário ficam mascarados, inclusive os do meio.

2. O **<|fim|>** tem de vir no fim de CADA resposta, e dá para decidir isso sem treinar.

Se ele aparecesse só no fim da conversa, a geração não teria onde parar ao terminar um turno — o modelo continuaria e **inventaria a fala do usuário**. É exatamente o comportamento do modelo-base que o capítulo inteiro combateu, só que agora dentro do formato.

3. É por isso que modelos reais usam um token de fim **por turno** (**<|im_end|>** e equivalentes), e não um marcador único de conversa.

E note que isso torna a conta do E2 **mais** relevante, não menos: numa conversa longa o histórico mascarado cresce e as respostas não. A fração de posições que seriam desperdiçadas sem máscara aumenta a cada turno — o regime desfavorável do E2 é o regime normal de um chat.

Gabarito — Capítulo 15

Respostas discursivas. Os **números** vêm de `experimento.py` e de `e4_dial_do_kl.py`.

```
bash python experimento.py # ~2h30 (3 configurações) python solucoes/e4_dial_do_kl.py
0.1 0.5 # ~50 min por beta
```

E1 — SFT e RL, lado a lado

1. De onde vem o sinal.

Método	Fonte do sinal
SFT	um alvo : existe um texto de referência, e a loss mede a distância até ele
RL	um juiz : não há texto de referência, e a loss mede se o que saiu pontuou bem

A diferença é de *fonte*, não de algoritmo. Os dois fazem descida de gradiente sobre os mesmos pesos.

2. Por que o RL precisa gerar.

Porque a recompensa é uma função da **saída**, e a saída não existe antes de o modelo produzi-la. No SFT o alvo já está no disco; aqui é preciso rodar o modelo até o fim para ter o que avaliar.

O custo é grande e é o motivo de este capítulo ser o mais lento do curso: cada passo de treino contém **48 passos de geração** — e com dois modelos, política e referência. Um passo de SFT é um forward e um backward; um passo de RL é 96 forwards mais um backward.

É por isso que RLHF é caro de um jeito que finetuning não é, e por que técnicas como o DPO — que eliminam a geração — ganharam tração tão rápido.

3. Por que o baseline não muda o gradiente esperado.

Porque $E[R - \text{média}(R)] = 0$. Subtrair uma constante que não depende da ação não altera a esperança do gradiente:

$$E[(R - b) \cdot \nabla \log P] = E[R \cdot \nabla \log P] - b \cdot \underbrace{E[\nabla \log P]}_{= 0}$$

O último termo é zero porque $E[\nabla \log P] = \nabla E[1] = 0$ — a soma das probabilidades é sempre 1, então o gradiente dela é nulo.

O que muda é a **variância**. Sem baseline, uma recompensa de 0,9 e outra de 0,8 são as duas "boas" e as duas são reforçadas com força parecida. Com baseline, a de 0,9 é reforçada e a de 0,8 é

penalizada — o sinal passa a ser sobre qual é melhor, não sobre qual é positiva.

E2 — Escreva uma recompensa ruim

A resposta é sua, mas há um padrão que quase sempre aparece e vale nomear.

Toda recompensa da forma "meça **X** como proxy de **Y**" tem uma região onde X e Y andam juntos — normalmente a região onde estão os dados naturais — e uma região onde eles se descolam. O RL vai direto para a segunda, porque é lá que X é maior.

Recompensa	X (medido)	Y (pretendido)	Onde descola
pontos	fração de tokens de pontuação	frases bem pontuadas	
comprimento mínimo	número de tokens	resposta completa	repetição, enrolação
"contém a palavra da pergunta"	sobreposição léxica	responde ao que foi perguntado	eco do enunciado
"poucas repetições"	tokens distintos	fluência	palavras raras aleatórias

3. O exercício pede para identificar o X e o Y da sua própria recompensa. Se você não conseguir separá-los, provavelmente escreveu Y como se fosse mensurável — e é justamente esse o momento em que uma recompensa ruim nasce parecendo razoável.

Note que **nenhuma** das quatro acima está "com bug". Todas medem exatamente o que dizem. O erro está em confundir a medida com a intenção.

E3 — O baseline importa mesmo?

1 e 2. Sem baseline, o aprendizado continua acontecendo — só que mais devagar e com a curva de recompensa muito mais ruidosa.

O motivo é o do E1: o gradiente esperado é o mesmo, então a direção média está certa. O que piora é a **variância** de cada estimativa individual. Com recompensas todas positivas, cada passo reforça tudo que foi amostrado, e o sinal útil — "isto foi melhor que aquilo" — fica submerso.

3. Recompensa sempre negativa é o caso que expõe o problema.

Se $R \in [-1, 0]$, então sem baseline **toda** ação é penalizada, sempre. O modelo empurra para baixo a probabilidade de tudo que gera, inclusive do que gerou a recompensa menos ruim. Ele aprende — porque as coisas piores são penalizadas mais — mas por um caminho absurdo: reduzindo a probabilidade de tudo, e diferenciando só pelas taxas.

Isso é o argumento para **normalizar recompensas** (subtrair a média, dividir pelo desvio). A escala e o deslocamento da sua recompensa não deveriam mudar o algoritmo, e sem normalização eles mudam.

E4 — Onde fica a faixa útil do β

Recompensa **pontos** (mal especificada), 400 passos, partindo de loss 4,0784:

β	Recompensa	KL	Loss real	Custo	Regime
0,00	0,058 -> 0,996	14,87	4,8211	+0,7427	hackeia por completo — 
0,02	0,058 -> 0,958	11,63	4,3963	+0,3179	hackeia quase igual — 
0,10	0,055 -> 0,218	1,41	4,0832	+0,0048	aprende sem custo
0,50	0,053 -> 0,064	0,31	4,0810	+0,0026	mal se move
2,00	0,053 -> 0,055	0,23	4,0800	+0,0016	congelado

1. A faixa útil existe, é $\beta \approx 0,1$ — e é um ponto só.

Em $\beta = 0,10$ a recompensa quadruplica (0,055 -> 0,218), a KL cai de 14,87 para 1,41, e o custo em português é **+0,005**, indistinguível de zero. A resposta volta a ser texto.

De um lado dele, em $\beta = 0,02$, o modelo hackeia quase completo. Do outro, em $\beta = 0,5$, ele paralisa: a recompensa sobe 0,011 em 400 passos. **Um fator de cinco para cada lado**, e a janela fecha.

Isso é desconfortável, e é o resultado. O β não é um parâmetro que você ajusta "mais ou menos" — é uma escolha entre três regimes qualitativamente diferentes, e só um deles serve.

2. A transição entre 0,02 e 0,10 é abrupta, e o motivo é estrutural.

A recompensa efetiva é $R - \beta \cdot KL$. O hacking total rende $R \approx 1$ e custa $KL \approx 15$. Então:

β	Ganho do hack	Custo do hack	Compensa?
0,02	+1,0	-0,30	sim, muito
0,10	+1,0	-1,50	não

O β não modula suavemente *quanto* o modelo hackeia — ele decide se hackear **vale a pena**. É uma mudança de sinal numa desigualdade, e por isso a transição parece um degrau em vez de uma rampa.

É a mesma forma do precipício entre 4 e 3 bits no [Capítulo 13](#): um parâmetro contínuo produzindo um comportamento com limiar.

3. Custo zero não é sucesso — e as duas últimas linhas provam.

Em $\beta = 0,5$ o custo é **+0,0026**, quase metade do custo em $\beta = 0,10$. Pela coluna do custo, seria a melhor configuração da tabela.

Olhe a recompensa: **0,053 -> 0,064**. Em 400 passos, o modelo aprendeu 0,011. Ele não foi protegido; foi **impedido de aprender**. Em $\beta = 2,0$ isso fica explícito — KL de 0,23, e a política praticamente não se moveu do ponto de partida.

É o mesmo formato de erro que o [Capítulo 13](#) encontrou na quantização: uma métrica que parece boa porque o sistema **não está fazendo nada**. Lá era o erro global escondendo linhas zeradas; aqui é o custo baixo escondendo um modelo que não treinou.

Por isso a tabela precisa das **duas** colunas. Otimizar só o custo leva ao β infinito, que é exatamente o mesmo que não treinar — e tem custo zero.

E5 — A recompensa não é o objetivo

1. As ordens são opostas.

Por recompensa (melhor -> pior)	Por loss em Machado (melhor -> pior)
pontos sem freio (0,996)	(partida, sem RL) — 4,0784
pontos com freio (0,958)	comprimento com freio — 4,1701
comprimento com freio (0,743)	pontos com freio — 4,3963
(partida) — sem recompensa	pontos sem freio — 4,8211

O **campeão** de recompensa é o **pior** modelo. Não é coincidência nem azar: ele é o pior justamente **porque** foi o melhor em otimizar a coisa errada.

2. O que um relatório só com a recompensa diria.

Diria: "o RL funcionou — a recompensa subiu 17 vezes". Cada palavra verdadeira, e a conclusão que o leitor tira é falsa.

O engano é específico: a recompensa **sempre sobe**. Ela mede se o otimizador está funcionando, não se o modelo melhorou. Reportá-la sozinha é reportar que o gradiente descendo — informação sobre o algoritmo, disfarçada de informação sobre o resultado.

3. Duas métricas que um projeto real precisa acompanhar:

Métrica	O que detecta que a recompensa não detecta
KL da referência	que a política está se afastando — o mecanismo, antes do dano

Desempenho numa tarefa que o RL não vê (aqui, loss em Machado)

que a capacidade original está sendo consumida

Uma terceira, quando há gente disponível: **avaliação humana em amostra**, justamente porque ela não pode ser otimizada diretamente pelo modelo. É por isso que laboratórios mantêm avaliações humanas caras mesmo tendo métricas automáticas baratas — a métrica barata é o que o modelo está otimizando, então ela é a que menos serve para julgá-lo.

E6 — Conserte a recompensa

1 e 2. Há consertos que ajudam: penalizar pontuação repetida, exigir um mínimo de tokens não-pontuação entre os pontos, medir a fração de *frases bem formadas* em vez de *caracteres de pontuação*.

Cada um fecha o buraco que você viu. E o modelo procura o próximo.

3. Não existe recompensa que resista a qualquer otimização, e isso não é pessimismo — é a estrutura do problema.

Se a recompensa é uma função computável da saída, e você otimiza contra ela com força suficiente, o modelo encontra o máximo dessa função. A pergunta nunca é "esta recompensa tem buracos?" — tem — e sim **"o máximo dela é aceitável?"**.

Isso reorganiza o que fazer:

Estratégia	Por que funciona (ou não)
escrever recompensa melhor	corrida sem fim — fecha um buraco, abre outro
limitar a otimização (KL, poucos passos)	compra tempo , não resolve — é o E4
recompensa verificável	muda o jogo: se o máximo é "a resposta está certa", hackear = acertar

A terceira é a razão de a área ter migrado para **matemática, código e tarefas com verificador**. Não é que esses domínios sejam mais importantes — é que neles a recompensa não é um proxy. Quando o teste passa, o teste passou.

E é a mesma conclusão do [E6 do Capítulo 11](#), chegando por outro caminho: dados gerados pelo próprio modelo ajudam **quando existe um verificador externo**. Lá era sobre dados, aqui é sobre recompensa, e o critério é o mesmo.

E7 — DPO (desafio)

1 e 2. A implementação é direta e vale pelo contraste: o DPO não gera durante o treino — ele consome pares prontos, com uma loss que se parece com uma cross-entropy. Um passo de DPO custa o mesmo

que um passo de SFT, contra os 96 forwards de um passo de REINFORCE.

3. O DPO não evita reward hacking, e a razão está no enunciado do exercício.

Você rotulou os pares com a **mesma recompensa ruim**. O DPO vai otimizar a preferência que recebeu, com a mesma obediência literal — e a preferência recebida diz que respostas com mais pontuação são melhores.

Trocar o algoritmo não conserta a especificação. O DPO elimina o modelo de recompensa explícito e o custo da geração; **não** elimina a distância entre o que você mediu e o que você queria.

Se a sua preferência vier de humanos, o problema muda de lugar mas não desaparece: humanos preferem respostas longas, confiantes e bem formatadas — e um modelo otimizado contra essa preferência aprende a ser longo, confiante e bem formatado. Inclusive quando está errado.

Gabarito — Capítulo 16

Respostas discursivas. Os **números** vêm de `carga.py`, rodado contra os dois servidores.

```
bash python servidor.py # terminal 1 python carga.py # terminal 2
```

E1 — TTFT e latência

1. O que o streaming melhora.

O **tempo até o usuário ver alguma coisa**, e nada mais. O servidor faz o mesmo trabalho, o texto é o mesmo, o total é o mesmo.

O que muda é a experiência: sem streaming, uma tela parada durante toda a geração e depois tudo de uma vez. Com streaming, a primeira palavra quase imediatamente e a leitura acompanha a produção.

É uma otimização de **latência percebida**, não de latência. A distinção parece acadêmica até você usar os dois.

2. Por que num LLM sim e num classificador não.

Porque a geração é **autorregressiva**: a saída é uma sequência produzida em ordem, e cada token existe antes do seguinte. Há o que transmitir aos poucos.

Um classificador produz **uma** saída, no fim de um único forward. Não existe "primeira metade da etiqueta". Não há nada para transmitir antes de terminar.

O streaming não é uma técnica que se aplica a qualquer modelo — ele é uma consequência de a saída ser sequencial.

3. Sem o `flush()`.

O sistema operacional acumula os bytes num buffer e envia quando ele enche ou quando a conexão fecha. O resultado prático: o cliente recebe tudo de uma vez, no fim — exatamente o comportamento do endpoint não-streaming.

E o código **continuará parecendo streaming**: o laço escreve token por token, o `Transfer-Encoding: chunked` está lá, tudo tem cara de certo. O defeito só aparece medindo o TTFT.

É o mesmo padrão do [Capítulo 12](#): um bug que não levanta exceção e só é detectável por medição.

E2 — Meça o seu próprio TTFT

Tokens pedidos	TTFT (stream)	Total (stream)	TTFT/total	Total (sem stream)
40	0,085 s	0,131 s	65,0%	0,117 s

200	0,084 s	0,872 s	9,6%	0,762 s
-----	---------	---------	------	---------

1 e 2. O TTFT é praticamente constante; o total é que cresce.

0,085 s com 40 tokens, 0,084 s com 200. Faz sentido: o primeiro token custa um prefill mais um passo de decode, e isso não depende de quantos tokens virão depois.

Então a razão TTFT/total **despenca** conforme a resposta cresce: de 65% para 9,6%. O streaming melhora pouco em respostas curtas e muito em respostas longas — e a tendência é mecânica, não empírica.

3. A extrapolação, e ela muda a leitura do capítulo.

Um modelo real a 30 tok/s, 500 tokens:

Medida	Sem streaming	Com streaming
tempo até ver algo	~17 s	~0,3 s
razão TTFT/total	100%	~1,8%

Dezessete segundos de tela parada é o que separa "está quebrado" de "está pensando". A magnitude de 30% medida no capítulo é pequena **porque o modelo é rápido demais para o efeito aparecer** — não porque o efeito seja pequeno.

Esta é a mesma armadilha do [Capítulo 12](#), onde o KV-cache rendeu 1,93x em vez das dezenas que a teoria sugeria: **a escala do curso comprime os ganhos**. O mecanismo é o que se aprende; a magnitude vem da escala em que você o aplica.

E3 — Por que threads não bastam

Clientes	Latência mediana	p95	Vazão total
1	0,15 s	0,15 s	268 tok/s
2	0,20 s	0,27 s	301 tok/s
4	0,32 s	0,50 s	320 tok/s
8	0,54 s	0,96 s	334 tok/s

1. Não cresce proporcionalmente — cresce 25% para 8x mais clientes. Se escalasse, os 334 seriam ~2.100.

2. Tirar a trava não resolve, e provavelmente piora.

Sem ela, oito threads chamam o modelo simultaneamente. Mas o PyTorch já usa **todos os núcleos** internamente numa única matmul — então as threads passam a disputar os mesmos núcleos, com troca de contexto e contenção de cache por cima.

O resultado típico é vazão igual ou pior, e latência mais irregular. **Meça antes de opinar** — este exercício existe para isso.

3. Por que agrupar resolve, e threads não.

O [Capítulo 12](#) estabeleceu que o decode é limitado por **memória**: para produzir um token é preciso ler **todos** os pesos do modelo. Lá isso foi medido — gerar 16 sequências em paralelo custou 9,1x menos que 16 gerações separadas.

A diferença é o que se compartilha:

Estratégia	Leituras dos pesos, para 8 clientes
8 threads independentes	8 (cada uma lê tudo)
1 lote de 8	1 (todos usam a mesma leitura)

Threads dividem o *tempo* de acesso ao modelo. O batching divide o *custo* de cada acesso. São coisas diferentes, e só a segunda ataca o gargalo real.

E4 — O tamanho do lote

Oito clientes, 40 tokens cada:

--lote	Latência mediana	Vazão	Ganho sobre lote 1
1	0,62 s	288 tok/s	—
4	0,47 s	514 tok/s	1,8x
16	0,47 s	673 tok/s	2,3x

1. A vazão mais que dobra de 1 para 16, e a latência **melhora** (0,62 -> 0,47 s). Não há troca aqui: mais lote é melhor nos dois eixos, até o ponto em que satura.

2. **--lote 1 deveria reproduzir o servidor sem batching. Não reproduz exatamente** — 288 tok/s contra 334 do `servidor.py`.

O que mais mudou: no `servidor_batch.py` toda requisição passa por **duas filas** (`queue.Queue`) e é servida por um thread que não é o do HTTP. Isso custa sincronização e troca de contexto por token. Com lote 1 você paga esse custo sem receber nada em troca.

Vale registrar como leitura de tabela: **--lote 1 não** é o controle limpo que parece. Ele isola o efeito do agrupamento, mas carrega a sobrecarga da arquitetura de filas.

3. O ganho satura, e a resposta é a mesma do E4 do Capítulo 8.

De 4 para 16 o ganho é bem menor que de 1 para 4. O que limita é o mesmo: em algum ponto o lote deixa de ser **limitado por memória** e passa a ser **limitado por cálculo** — a matmul fica grande o bastante para ocupar os núcleos, e dali em diante dobrar o lote dobra o tempo.

A diferença é que aqui há um segundo limite, que o Capítulo 8 não tinha: o **KV-cache cresce com o lote** (Capítulo 12). Em escala real, é a memória que fecha a conta antes do cálculo.

E5 — A espera que custou caro

1. A conta bate.

Com a espera de 8 ms por passo, a latência foi de 0,15 s (servidor simples) para **0,62 s**. A diferença é 0,47 s, contra os $40 \times 8 \text{ ms} = 0,32 \text{ s}$ previstos — a mesma ordem, com o resto vindo da sobrecarga das filas medida no E4.

2. Sim, existe um cenário em que ela ajuda: chegadas espaçadas.

Se as requisições chegam de forma dispersa — uma a cada 5 ms, digamos — esperar um pouco antes de começar junta várias num lote maior. Sem espera, a primeira requisição começa sozinha e as seguintes perdem a carona.

É um compromisso real, e tem nome em sistemas de fila: **esperar aumenta a latência de quem já chegou para aumentar a vazão de todos**. Serviços de verdade expõem isso como um parâmetro (`max_waiting_time`, ou equivalente).

O erro da minha versão não foi ter espera — foi **esperar a cada passo de decode** em vez de só na formação do lote. Esperar uma vez custa 8 ms; esperar 40 vezes custa 320.

3. A regra:

Nunca bloqueie quando há trabalho a fazer. Bloqueie apenas quando estiver ocioso.

Ela aparece em qualquer laço de serviço. Um exemplo fora daqui: um consumidor de fila de mensagens que faz `poll(timeout=100ms)` mesmo tendo mensagens no buffer local — ele adiciona 100 ms a cada ciclo por nada. O padrão correto é drenar o que já está disponível sem bloquear, e só então esperar.

E6 — O p95 conta o que a média esconde

1. Por que diferentes num caso e iguais no outro.

Servidor	Mediana	p95
com trava	0,54 s	0,96 s
com batching	0,42 s	0,42 s

Com a trava existe uma **fila**: as requisições são atendidas em sequência, então a primeira espera pouco e a oitava espera sete gerações. A distribuição tem cauda porque as posições na fila são diferentes.

Com batching **todos avançam no mesmo passo** — cada iteração produz um token para o lote inteiro. Não há posição na fila, então não há cauda.

p95 = mediana é a assinatura de um sistema onde ninguém espera pelos outros. Vale procurar por isso em qualquer serviço que você meça: quando os dois números se separam, há uma fila em algum lugar.

2. Média 200 ms, p99 de 4 s.

Uma em cada cem requisições demora **vinte vezes** a média. Para o usuário isso não é "às vezes um pouco mais lento" — é o sistema travando de vez em quando, sem padrão aparente.

E numa página que faz 10 chamadas, a chance de pelo menos uma cair no p99 é de ~10%. A cauda que parecia rara vira comum quando as requisições se acumulam.

Reportar só a média esconde precisamente o que o usuário lembra.

3. Outra métrica de cauda para um serviço de LLM:

O **p95 do TTFT**, separado do p95 da latência total. São coisas diferentes: um servidor pode ter TTFT estável e latência total com cauda (respostas de tamanhos muito variados), ou o contrário (fila na admissão). Só medindo os dois dá para saber onde está o problema.

Uma segunda: a **taxa de requisições recusadas ou expiradas**. Ela é zero até o sistema saturar, e depois é a métrica mais importante que existe — e não aparece em nenhuma estatística de latência, porque as requisições que falharam não têm latência.

E7 — Backpressure (desafio)

1 e 2. Com fila ilimitada, a latência cresce sem limite: a 64 clientes cada um espera o lote inteiro várias vezes, e as requisições mais antigas provavelmente já expiraram do lado do cliente — o servidor gasta trabalho gerando respostas que ninguém vai ler.

O limite deve sair da sua medição: escolha o N tal que a latência do último da fila ainda seja aceitável para o seu caso.

3. Por que recusar pode ser melhor que atender devagar.

Três razões, e a terceira é a que menos se pensa:

- **Um 429 é acionável.** O cliente sabe imediatamente que deve tentar depois, ou ir para outra réplica. Uma resposta que demora 40 s não informa nada — ele fica esperando.
- **Trabalho desperdiçado prejudica quem está sendo atendido.** Gerar tokens para um cliente que já desistiu consome exatamente os mesmos recursos de quem ainda está lá.
- **Sem limite, a degradação é global.** Com fila ilimitada, sobrecarga não faz alguns falharem — faz **todos** ficarem lentos. Recusar concentra o dano em quem chegou por último, em vez de espalhá-lo

por todos.

É a mesma escolha que o E6 revela na tabela: um sistema pode falhar de forma **concentrada e visível** ou **difusa e silenciosa**. A primeira é quase sempre melhor de operar — e é o mesmo argumento que o [Capítulo 12](#) fez sobre o gloo travar sempre em vez de às vezes.

Gabarito — Capítulo 17

Respostas discursivas. Os **números** vêm de `gabarito.py`, que roda com **600 passos** por variante (a apostila usa 1.500) — são vários treinos.

```
bash python solucoes/gabarito.py
```

E1 — Por que quantizar

1. Compressão.

Medida	Pixels	Tokens	Razão
posições	784	49	16x
bits	$784 \times 8 = 6.272$	$49 \times 7 = 343$	18x

Em posições e em bits a compressão é parecida — o que se ganha em quantidade de símbolos, gasta-se um pouco em cada símbolo ser mais "caro" (7 bits contra 8). O ganho real é o primeiro: **o que limita um Transformer é o comprimento da sequência**, não a largura do vocabulário. Reduzir 784 para 49 é a diferença entre caber e não caber.

2. Por que não usar os vetores contínuos direto.

Porque a **saída** do modelo é uma distribuição sobre um conjunto finito. Um Transformer autorregressivo termina numa softmax: ele escolhe entre K opções, amostra uma, e realimenta.

Com vetores contínuos não há o que amostrar — você teria de prever um vetor de 32 números reais, e a loss viraria um erro quadrático em vez de uma cross-entropy. Isso é possível (existem modelos assim) e muda o objetivo de "modelar uma distribuição" para "prever a média", que produz saídas borradas.

A quantização não é só compressão: é o que permite **amostrar**.

3. A analogia com o BPE, e onde ela quebra.

Onde funciona: ambos aprendem um alfabeto de pedaços recorrentes a partir dos dados, ambos reduzem o comprimento da sequência, e ambos são específicos do domínio em que foram treinados (o [E3 do Capítulo 11](#) mediu isso para texto).

Onde quebra: o BPE é **exato** — decodificar desfaz o encode perfeitamente. O VQ-VAE **perde informação**: a reconstrução é aproximada, e o erro de 0,0039 é justamente essa perda. Um é compressão sem perdas de símbolos discretos; o outro é compressão com perdas de um sinal contínuo.

E2 — O straight-through estimator

Variante	Erro de reconstrução	Códigos usados
com straight-through	0,0069	67
sem straight-through	0,0756	1

1. Sem o straight-through, tudo colapsa. O erro fica 11x pior — e, mais revelador, **um único código** é usado para o dataset inteiro.

O decoder ainda aprende: ele recebe gradiente normalmente. O que não aprende é o **encoder** — o **argmin** corta a cadeia, nada diz a ele que vetores produzir, e ele fica essencialmente na inicialização. Com o encoder parado, todos os vetores caem perto do mesmo lugar, e a quantização vira uma constante.

2. O que a linha faz.

```
z_q = z + (z_q - z).detach()
```

Fase	Valor
forward	$z + z_q - z = z_q$ — o vetor quantizado, exato
backward	$d/dz [z + \text{constante}] = 1$ — passa direto para o encoder

O **.detach()** congela o *nó no grafo*, não o número. É contabilidade de derivadas, não aritmética: o valor calculado é idêntico, e só o caminho do gradiente muda.

3. Por que uma aproximação funciona.

O encoder recebe o gradiente do decoder como se a quantização não existisse. Isso é falso — mas é **quase** verdade, porque **z** e **z_q** são próximos por construção.

E são próximos justamente porque o *commitment loss* os mantém assim. As duas peças se sustentam: a aproximação é boa exatamente na medida em que a outra perda faz o seu trabalho.

E3 — As duas perdas

BETA_COMP	Erro	Códigos usados
0,00	0,0755	1
0,25 (o do artigo)	0,0069	67
2,00	0,0046	105

1. Com **BETA_COMP = 0** o resultado é catastrófico — e é o mesmo colapso do E2, por outra causa. Sem nada que o prenda, o encoder foge para uma região que o codebook não alcança, e todo vetor cai no mesmo código.

2. E aqui eu estava errado.

Eu tinha escrito que **BETA_COMP** alto prenderia o encoder e pioraria a representação. Medido, **2,0 é o melhor dos três nos dois eixos**: erro 0,0046 contra 0,0069, e 105 códigos usados contra 67.

O valor 0,25 é o do artigo original do VQ-VAE, e eu o tratei como se fosse um ótimo demonstrado. Nesta configuração — MNIST, codebook de 128, 600 passos — não é. Um *commitment* mais forte mantém o encoder perto do codebook, o que faz mais códigos serem alcançáveis, o que melhora tudo.

A lição não é "use 2,0". É que **um hiperparâmetro herdado de um artigo foi ajustado para outra configuração** — outro dataset, outro tamanho, outro orçamento. Vale medir na sua.

É o mesmo padrão do [Capítulo 11](#), onde a melhor learning rate mudou conforme o orçamento de treino.

3. O papel de cada perda:

Perda	O que ela move
<code>perda_codebook</code>	o codebook , em direção ao encoder
<code>perda_commit</code>	o encoder , em direção ao codebook

São os dois lados do mesmo encontro, e cada uma move um lado.

Removendo a `perda_codebook`, os vetores do codebook só se moveriam pelo gradiente que chega via decoder — muito mais fraco. Na prática ele ficaria quase congelado na inicialização, e o encoder teria de se contorcer para caber num alfabeto aleatório.

E4 — Códigos mortos

Codebook	Usados	Fração	Erro
32	32	100%	0,0070
64	55	86%	0,0065
128	67	52%	0,0069
256	57	22%	0,0066

1. A fração usada cai, e o erro quase não melhora.

De 32 para 256 códigos — oito vezes mais capacidade nominal — o erro vai de 0,0070 para 0,0066. Praticamente nada. **Um codebook maior não vira mais capacidade; vira mais códigos mortos.**

O mecanismo é de realimentação: para ser escolhido, um código precisa estar perto de algum vetor do encoder; para chegar perto, precisa ser escolhido e receber gradiente. Quem nasce longe nunca entra no jogo.

É o mesmo formato do colapso do E2 e do E3, e vale notar que os três aparecem por caminhos diferentes: sem gradiente no encoder, sem commitment, ou por inicialização azarada. O VQ-VAE tem várias maneiras de degenerar para "poucos códigos fazem tudo".

2 e 3. A correção, e o que ela realmente melhora.

Reinicializar códigos mortos sobre vetores do batch quase sempre **aumenta muito a fração usada e melhora pouco o erro de reconstrução**.

Isso não a torna inútil — torna-a mal avaliada pela estatística de uso. O ganho real aparece depois: um codebook bem aproveitado dá ao Transformer um vocabulário mais informativo, e é lá que se deve medir.

Cuidado com a métrica que melhora sem que o sistema tenha melhorado no que importa. É o mesmo tipo de armadilha do [Capítulo 15](#), onde $\beta = 0,5$ tinha o menor custo em português — porque o modelo não estava aprendendo nada.

E5 — O mesmo Transformer

1. Zero linhas do modelo mudaram.

```
from modelo import GPT
```

É a mesma classe, byte por byte, que escreveu prosa nos capítulos 11 a 15. O que muda é a config:

Config	vocab_size	block_size	n_embd
Capítulo 11 (texto)	1.024	128	192
Capítulo 17 (imagem)	128	49	128

2. A comparação de perplexidade não é justa, e entender por que vale mais que o número.

Modelo	Perplexidade	Vocabulário	Normalizada
Capítulo 11	51,7	1.024	5,0%
Capítulo 17	3,9	128	3,0%

Perplexidade é "entre quantas opções o modelo está efetivamente escolhendo". Comparar 3,9 com 51,7 ignora que os vocabulários diferem 8x.

E mesmo normalizada a comparação é fraca, porque as **tarefas** são diferentes: prever o próximo pedaço de um dígito manuscrito é bem mais restrito que prever a próxima palavra de Machado. Perplexidades só se comparam dentro da mesma tarefa e do mesmo tokenizador.

3. A ordem de varredura é arbitrária para imagem, e cria um problema real.

O modelo gera da esquerda para a direita, de cima para baixo — porque é assim que se achatou o mapa 7×7. Mas imagem não tem ordem natural, e a consequência é concreta: **o modelo desenha a parte de cima sem saber o que virá embaixo, e não pode voltar atrás**. Um traço mal começado no topo condena o dígito inteiro.

Texto tem ordem natural (o tempo); imagem não tem. Alternativas:

Abordagem	Ideia
ordem aleatória	o modelo recebe a posição junto com o token e pode gerar em qualquer ordem
múltiplas escalas	gera uma versão grosseira primeiro, refina depois
difusão	abandona a autorregressão: refina a imagem inteira de uma vez, várias vezes

A terceira é a que dominou geração de imagem, e a razão é exatamente esta: ela não precisa escolher uma ordem.

E6 — Condicionar pelo dígito

O caminho é o mesmo do [Capítulo 14](#): reserve ids novos acima do vocabulário existente (aqui, 128 a 137 para os dez dígitos), expanda a tabela de embeddings e a camada de saída, e ponha o rótulo como primeiro token da sequência.

3. O que mudaria para condicionar por uma legenda de verdade.

Estruturalmente, **quase nada** — e é esse o ponto. Em vez de um token de condição, você põe a legenda tokenizada pelo BPE do Capítulo 6:

```
<|texto|> um dígito sete inclinado <|imagem|> t1 t2 ... t49
```

O modelo aprende a prever os tokens de imagem condicionados aos de texto, com a mesma loss de sempre.

O que muda de verdade é o **dado**: você precisa de pares imagem-legenda, e é por isso que este capítulo usa o rótulo do MNIST em vez de legendas. Dez rótulos existem; um corpus pareado útil começa em dezenas de gigabytes.

A arquitetura de um "texto -> imagem" não é o obstáculo. O obstáculo são os dados pareados — a mesma conclusão que o Capítulo 11 tirou sobre texto, em escala maior.

E7 — Um modelo, duas modalidades (desafio)

1 e 2. Juntar os vocabulários funciona mecanicamente: ids 0-1023 para texto, 1024-1151 para imagem, e um GPT treinado em sequências dos dois tipos. Espere alguma interferência — a capacidade é dividida entre duas distribuições sem relação.

3. A pergunta que importa: o modelo aprende alguma relação entre as modalidades? Não.

E a razão está no objetivo de treino. O modelo é recompensado por prever o próximo token **dentro de cada sequência**. Se nenhuma sequência contém texto e imagem, nada no gradiente jamais liga um token de texto a um token de imagem — as duas metades do vocabulário nunca coocorrem.

O resultado é **um modelo com duas personalidades**, não um modelo multimodal. Ele modela duas distribuições que por acaso compartilham pesos.

Para que aprendesse, seria preciso o que este capítulo não tem: **sequências que misturem as duas modalidades**. É por isso que dados pareados são o recurso caro em multimodalidade — e por que "juntar os tokenizadores" resolve a parte fácil do problema.

Vale terminar o curso com isto: a arquitetura quase nunca é o obstáculo. Do Capítulo 1 ao 17, o que mudou a qualidade foi sempre **dados, escala e medição honesta** — nunca uma ideia arquitetural esperta.